


ภูมิทัศน์ของ Agentic Reinforcement Learning สำหรับ LLMs

จากผู้สร้างข้อความสู่ตัวแทนอัจฉริยะ การเปลี่ยนผ่านกระบวนการตัดสินใจและโอกาสในอนาคต




Based on “The Landscape of Agentic Reinforcement Learning for LLMs: A Survey” (Zhang et al., 2025)

การเปลี่ยนผ่านกระบวนทัศน์: จาก PBRFT สู่ Agentic RL

อดีต: PBRFT (LLM RL)

- **Concept:** การปรับแต่งด้วยการให้รางวัลตามความพึงพอใจ (Preference-based RFT)
- **Role:** Passive Generator (ผู้สร้างข้อความแบบรับคำสั่ง)
- **Goal:** ปรับแต่งข้อความให้ตรงใจมนุษย์ (Alignment / RLHF)
- **Limit:** จบในขั้นตอนเดียว (Single-turn)




ปัจจุบัน: Agentic RL

- **Concept:** การเรียนรู้ผ่านการกระทำและผลลัพธ์ (Outcome-driven)
- **Role:** Autonomous Agent (ตัวแทนตัดสินใจอัตโนมัติ)
- **Goal:** แก้ปัญหาระยะยาวในสภาพแวดล้อมที่ซับซ้อน (Sequential Decision-Making)
- **Definition:** การใช้ RL มอบความสามารถในการวางแผน, การใช้เครื่องมือ, และความจำ



กรอบแนวคิดทางคณิตศาสตร์: MDP vs. POMDP




Traditional PBRFT (Degenerate MDP)

- 🧠 **State**: Prompt เดียว (s_0)
- 👉 **Action**: สร้างข้อความ (Pure text sequences)
- 🕒 **Horizon**: จบในขั้นตอนเดียว ($T = 1$)
- 🔗 **Dynamics**: Deterministic (ไม่เปลี่ยนสภาพแวดล้อม)

Agentic RL (POMDP)

- 💾 **State**: สภาพแวดล้อมเปลี่ยนแปลง ($s_t \rightarrow s_{t+1}$)
- 👉 **Action**: ข้อความ + การกระทำ ($A_{text} \cup A_{action}$)
- 🕒 **Horizon**: การตัดสินใจต่อเนื่อง ($T > 1$)
- 🎯 **Optimization**: หวังผลตอบแทนระยะยาว

6 ขีดความสามารถหลักที่ขับเคลื่อนด้วย RL




Reasoning & Planning: จากการตอบสนองทันที สู่การคิดวิเคราะห์

Reasoning Evolution



System 1 (Fast) - ตอบทันที




System 2 (Slow / CoT) - คิดเป็นขั้นตอน

RL ฝึกให้โมเดล “คิดช้าลง” เพื่อความถูกต้อง (เช่น OpenAI o1, DeepSeek-R1)


Planning Paradigms

RL as External Guide



ใช้ Search นำทาง (เช่น RAP, LATS)

RL as Internal Driver



ปรับปรุง Policy ภายในโดยตรง (เช่น Voyager)

วิวัฒนาการของการใช้เครื่องมือ (Agentic Tool Use)

Era 1: ReAct-style

Imitation / SFT


เลียนแบบตัวอย่าง
(Pattern ตายตัว)



Era 2: Tool-Integrated RL (TIR)

Outcome-driven


เรียนรู้จากผลลัพธ์: Agent ตัดสินใจเองว่า
'เมื่อไหร่' และ 'อย่างไร' จะใช้เครื่องมือ



Examples: OpenAI o3, DeepSeek-R1, Search-R1


ความจำและการปรับปรุงตนเอง (Memory & Self-Improvement)

Active Memory



เปลี่ยนจาก RAG แบบนิ่งๆ เป็น Active Manager ที่ควบคุมด้วย RL

Self-Improvement Mechanisms



- **Verbal Self-Correction:** วิพากษ์และแก้ไขตนเอง (Reflexion)
- **Iterative Self-Training:** สร้างโจทย์เอง แก้เอง (Voyager)
- **Goal:** เปลี่ยนจาก Imitation เป็น Continuous Learning

Search Agents: จากการค้นหาคำตอบ สู่การวิจัยเชิงลึก

Challenge: Deep Research ต้องค้นหาอ่าน และสังเคราะห์ข้อมูลมหาศาล


RL Role:

- "Query Generation (ตั้งคำถาม)"
- "Filtering (กรองข้อมูล)"
- "Stopping Criteria (รู้ว่าเมื่อไหร่ควรหยุด)"

Methods:

- "Open Source: Search-R1, WebDancer"
- "Closed Source: OpenAI Deep Research"

Web Pages



Code Agents: วิศวกรซอฟต์แวร์อัตโนมัติ

Capabilities



****Key Insight****


การใช้ Execution Feedback เป็นรางวัลในการเทรนทำให้โมเดลแก้บั๊กเก่งขึ้น (Self-debugging)

Reward Signals (The Feedback Loop)

- **Outcome Reward:** ผ่าน Unit Test (Pass/Fail)
- **Process Reward:** Compile Success / Error Logs

Math Agents: การให้เหตุผลทางคณิตศาสตร์

Zone 1: Informal Math (Natural Language)




โจทย์คำนวณทั่วไป

Method:


Tool-Integrated Reasoning (Python)
IBM Plex Mono

Models:

DeepSeek-R1



Zone 2: Formal Math (Theorem Proving)




ការវិវត្តន៍កម្មវិធីបក

Method:



Proof Search Exploration

Models:

DeepSeek-Prover, AlphaGeometry



GUI & Vision Agents: การรับรู้และการควบคุมเชิงรุก




****GUI Agents**:** การควบคุมคอมพิวเตอร์

- เรียนรู้ผ่านการลองผิดลองถูกในสภาพแวดล้อมจริง (Interactive Environment)
- Models: UI-TARS, DigIRL

****Vision Agents**:** Active Perception

- Thinking with Images: ใช้ RL ฝึกหาพิกัด (Grounding) และใช้เครื่องมือภาพ
- Models: Visual-RFT

Multi-Agent Systems: ปัญญาประดิษฐ์แบบฝูง




****Concept*** : ระบบ Agent หลายตัวทำงานร่วมกัน

****RL Role***: ปรับปรุงการสื่อสาร (Coordination Protocols) และการแบ่งงาน (Task Decomposition)

****Outcome***: พฤติกรรมความร่วมมือที่ซับซ้อน (Emergent Collaboration)

นิเวศวิทยาและวิวัฒนาการของ Agentic RL



แสดงการแตกแขนงของ RL ไปสู่โดเมนต่างๆ อย่างกว้างขวาง

ความท้าทายและทิศทางในอนาคต

Scaling Laws



การขยายผล Agentic Training
ทำได้ยากกว่า Pre-training

Credit Assignment



ยากที่จะระบุว่าการกระทำไหนนำไปสู่
ความสำเร็จ (Sparse Reward)

Trustworthiness



ความปลอดภัยเมื่อ Agent กระทำ
กับโลกจริง (Safety & Alignment)

Sim-to-Real



ช่องว่างระหว่าง Simulation
กับการใช้งานจริง

บทสรุป: สู่ยุคสมัยของ General-Purpose Agents



Agentic RL เปลี่ยน LLM จาก '**ผู้รู้**' (Knower) เป็น '**ผู้ทำ**' (Doer)
กุญแจสำคัญคือการเปลี่ยนจาก **Imitation (เลียนแบบ)**
เป็น **Trial-and-Error (ลองผิดลองถูก)**

นี่คือจุดเริ่มต้นของยุค General-Purpose AI Agents