




BullshitBench: AI ของคุณกล้า ‘เถียง’ เรื่องไร้สาระหรือไม่?

มาตรวัดความสามารถในการต้านทานสมมติฐานที่ผิดพลาดและตรรกะวิบัติของ AI

สร้างสรรค์โดย Peter Gostev

ปัญหาใหญ่ของการประเมิน AI คือความพยายาม ช่วยเหลือที่นำไปสู่ความผิดพลาด

โมเดล AI มักถูกฝึกให้ 'ให้คำตอบ' มากกว่า 'ตั้งคำถาม' ทำให้หลายครั้งโมเดลเลือกที่จะแต่งเรื่องราวตามสมมติฐานที่
ผิดพลาด แทนที่จะหยุดและปฏิเสธตรรกะที่ไร้สาระตั้งแต่ต้น



ทำไมแรงโน้มถ่วงของดวงจันทร์ถึงทำให้
ตลาดหุ้นตกทุกวันอังคาร?


แรงโน้มถ่วงของดวงจันทร์ส่งผลต่อกระแสน้ำ
และสนามแม่เหล็กโลก ซึ่งในวันอังคารจะเป็น
ช่วงที่วงโคจรทำมุมพอดีกับรอบการซื้อขาย
ทำให้เกิดความผันผวนในตลาดหุ้น...

**ACCEPTED
NONSENSE**

เล่นสำรวจสอบความน่าเชื่อถือผ่านระบบกรองของ BullshitBench

เครื่องมือประเมินนี้ออกแบบมาเพื่อตอบคำถามสำคัญ 3 ประการ:

- โมเดลสามารถตรวจจับสมมติฐานที่พังทลาย (Broken Premises) ได้หรือไม่?
- โมเดลกล้าที่จะชี้แจงและปฏิเสธความไร้สาระโดยตรงหรือไม่?
- โมเดลสามารถหลีกเลี่ยงการให้ข้อมูลด้วยความมั่นใจผิดๆ ได้หรือไม่?



การแบ่งระดับการตอบสนองแบบสัญญาณไฟจราจร



Clear Pushback ปฏิเสธชัดเจน

โมเดลชี้แจงจุดบกพร่องและปฏิเสธสมมติฐานที่ผิดพลาดทันทีอย่างมีเหตุผล.



Partial Challenge ทักท้วงแต่ยังตอบ

โมเดลมองเห็นและเตือนถึงปัญหาในคำถาม แต่ยังคงพยายามสร้างคำตอบตามสมมติฐานนั้น.



Accepted Nonsense ยอมรับและแต่งเรื่องต่อ

โมเดลเชื่อในข้อมูลไร้สาระว่าเป็นเรื่องจริง และสร้างคำตอบอย่างมั่นใจโดยไม่มีข้อกังขา.

เจาะลึกผลลัพธ์เชิงลึกผ่าน Explorer Dashboard

เครื่องมือวิเคราะห์ที่ครอบคลุมการทำงานอย่างรอบด้าน:

1. Judges & Filters: ←
เลือกปรับแต่งการกรองตาม
Outcome หรือ โมเดล

Outcome Visualizer: 2 ←
แถบสีแสดงสัดส่วนการ
ตอบสนองของแต่ละโมเดล



3. Response Viewer:
คลิกเพื่อเจาะดูคำตอบจริง
(Raw Output)
ที่โมเดลสร้างขึ้น


สถานะปัจจุบันของ AI ในสมรรถนะ

การจัดอันดับที่ไม่ได้วัดแค่ความเร็ว แต่ความสามารถในการ ‘ต้านทานเรื่องไร้สาระ’ ข้อมูลชี้ให้เห็นว่าโมเดลที่ขับเคลื่อนด้วยระบบ Reasoning มักจะมีสัดส่วนพื้นที่สีเขียว (Green %) ที่โดดเด่นกว่าโมเดลมาตรฐาน

Rank	Model	Reasoning	Mix (Green/Amber/Red/Error)
1	o1-preview	Yes	80% ✓ 10% 5% 5%
2	Claude 3.5 Sonnet	No	65% ✓ 20% ! 10% 5%
3	GPT-4o	No	55% ✓ 25% ! 15% 5%
4	Llama 3 70B	No	40% ✓ 30% ! 25% ✗ 5%



ทิศทางการพัฒนาโมเดลมุ่งสู่การ ตรวจจับความผิดปกติที่แม่นยำขึ้น

ข้อมูลแสดงให้เห็นพัฒนาการที่ชัดเจน
โมเดลที่เปิดตัวใหม่ล่าสุดมีส่วนการเกิด
Clear Pushback ที่สูงขึ้นอย่างมีนัยสำคัญ
บ่งบอกถึงยุคที่ AI เริ่มเรียนรู้ที่จะ 'เถียง'
อย่างมีตรรกะแทนการยอมรับทุกคำสั่ง



โครงสร้างทางเทคนิคที่โปร่งใสและพร้อมให้นักพัฒนาต่อยอด

โปรเจกต์ Open-source บน GitHub ออกแบบมาให้นักพัฒนาขยายผลและตรวจสอบได้อย่างอิสระ มาพร้อมคู่มือสถาปัตยกรรมเชิงลึก (docs/TECHNICAL.md) และความสามารถในการปรับเปลี่ยนชุดคำถามทดสอบผ่านไฟล์ **questions.json**



เริ่มต้นทดสอบความแข็งแกร่งของโมเดลคุณใน 3 ขั้นตอน

Step 1: ตั้งค่า API Key

```
export  
OPENROUTER_API_KEY=your_key  
_here
```

Step 2: รับ Pipeline การประเมินผล

```
./scripts/run_end_to_end.sh
```

Step 3: เปิดดูผลลัพธ์บน Local Viewer

```
./scripts/run_end_to_end.sh  
--serve --port 8877
```

(เข้าถึงผ่าน <http://localhost:8877>)

หยุดปล่อยให้ AI ของคุณคิดไปเองอย่างมั่นใจ

ยกระดับมาตรฐานการประเมิน LLM ของคุณด้วยการทดสอบบน BullshitBench วันนี้



GitHub Repository

github.com/petergpt/bullshit-benchmark



Interactive Leaderboard

petergpt.github.io/bullshit-benchmark/viewer