


CASTLE: การปฏิวัติกลไก Attention ด้วย Lookahead Keys

ก้าวข้ามขีดจำกัดของ Static Context สู่การเรียนรู้แบบ Dynamic ที่แม่นยำยิ่งขึ้น



ปัญหาของ Causal Attention แบบดั้งเดิม: "บริบทที่ถูกแช่แข็ง"


The 'Garden Path' Problem:

ประโยคที่มีความกำกวมทางโครงสร้าง (Structural Ambiguity) ทำให้โมเดลตีความผิดพลาดไม่สามารถย้อนกลับไปได้
ความเข้าใจในอดีตได้

Static Keys Limitation:


ใน Standard Attention, ทันทีที่ Token ถูกประมวลผล Key ของมันจะเป็นค่าคงที่ (Fixed) ไม่สามารถเรียนรู้บริบทใหม่ที่ตามมาทีหลังได้

DIAGRAM 01: GARDEN PATH SENTENCE INTERPRETATION FLOW




CASTLE: เปลี่ยน “Static Eyes” ให้เป็น “Evolving Perception”

Standard Attention




CASTLE



CASTLE (Causal Attention with Lookahead Keys) คือกลไกที่ Keys ของ Tokens ในอดีต จะถูกอัปเดตตลอดเวลาเมื่อมี Context ใหม่เข้ามา (Token s รับรู้ข้อมูลจาก $s + 1$ ถึง t)


สถาปัตยกรรมแบบ Hybrid: ผสานความเสถียรและความยืดหยุ่น

Hybrid Architecture: Combining Stability and Flexibility



“เราไม่ได้ทิ้งวิธีเดิม แต่เราเพิ่มมิติของการเรียนรู้ที่ลึกซึ้งยิ่งขึ้น”

เจาะลึก Lookahead: การมองเห็นย้อนกลับ (Backward Dependency)



****Note on Autoregressive:****
Receptive fields

กระบวนการนี้เกิดขึ้นภายใน Step ปัจจุบันเท่านั้น ไม่มีการข้ามไปดูข้อมูลที่ยังไม่ได้ Generate

ความท้าทายทางวิศวกรรม: กับดักของความซับซ้อน ($O(L^3)$)



The Problem:
การอัปเดต Keys ย้อนหลังในทุกๆ Step (Recurrent Form) ทำให้ต้องคำนวณซ้ำซ้อน

Cost:
ความซับซ้อนพุ่งสูงถึง $O(L^3)$ ซึ่งเป็นไปไม่ได้สำหรับการ Pretraining โมเดลขนาดใหญ่ (เช่น LLaMA หรือ GPT-3)


Impact:
หากใช้วิธีตรงไปตรงมา การเทรนโมเดลจะช้าจนไม่คุ้มค่าทางเศรษฐกิจ

ทางออก: การฝึกแบบขนานที่มีประสิทธิภาพ (Efficient Parallel Training)


Step-by-Step
($t = 1, t = 2 \dots$)



Theorem 1



Blockwise Matrix Operation




****Mathematical Equivalence:** ที่มวิจัย
ค้นพบสมการที่
เทียบเท่ากันทาง
คณิตศาสตร์ แต่ไม่ต้อง
Materialize
Lookahead Keys จริงๆ

Result:
ลดความซับซ้อนกลับ
ลงมาเหลือ $O(L^2)$
(เท่ากับ Standard
Attention!)

เจาะลึกอัลกอริทึม: ทำไมต้อง Sigmoid?


$$\text{sigmoid} \left(\frac{Q_t^U K_t^{U^\top}}{\sqrt{d}} + M_t^U \right) V_t^U$$

Softmax



บังคับให้ผลรวมความน่าจะเป็นเท่ากับ 1
ทำให้ข้อมูลแย่งความสำคัญกัน
(Compulsory synthesis)


Sigmoid




ทำหน้าที่เป็น Gate ที่อนุญาตให้รวบรวมข้อมูลจาก
อนาคตได้ตามความเหมาะสม ไม่จำเป็นต้องบังคับ
(Adaptive synthesis)

การใช้งานจริง: UQ-KV Cache สำหรับ Inference

Standard KV Cache



UQ-KV Cache



****Optimized Memory:** แทนที่จะคำนวณใหม่ทั้งหมด เรา Cache ค่า U^t (Lookahead Key) และ Q^U ไว้

****Recursive Update:** ใช้สมการ Recursive เพื่ออัปเดต U^t จาก U^{t-1} ได้ทันที


****Speed:** ความซับซ้อนในการ Decoding อยู่ที่ $O(td)$ เท่านั้น (รวดเร็วเทียบเท่าโมเดลปกติ)

การตั้งค่าการทดลอง (Experimental Setup)

Category	Detail
Base Architecture	LLaMA-like (SwiGLU, Rotary Embeddings, RMSNorm)
Dataset	FineWeb-Edu (50B tokens)
Comparison	Standard Causal Attention vs. CASTLE
Model Scales	Small (0.16B) Medium (0.35B) Large (0.75B) XL (1.3B) - Equivalent to GPT-3 scale config


เปรียบเทียบโดยควบคุมตัวแปรอื่นให้คงที่ เพื่อวัดประสิทธิภาพของ Attention Mechanism เพียงอย่างเดียว

ผลลัพธ์: ยิงโมเดลใหญ่ ประสิทธิภาพยิ่งแตกต่าง



- **Validation Loss:** ลดลงอย่างมีนัยสำคัญในทุกขนาดโมเดล
- **XL Model: ส่วนต่าง (Gap) กว้างที่สุดที่ -0.0348** (แสดงให้เห็นว่าโมเดลขนาดใหญ่ใช้ประโยชน์จาก Global Context ได้ดีกว่า)
- **Perplexity:** ลดลงจาก 11.309 เหลือ 10.922 (ในรุ่น XL)

ประสิทธิภาพในงานจริง: ความโดดเด่นด้านการใช้เหตุผล (Reasoning)




Insight: CASTLE ทำคะแนนได้ดีกว่าในงานที่ต้องใช้ความเข้าใจบริบทซับซ้อน (ARC, HellaSwag)
Conclusion: Lookahead Keys ช่วยให้โมเดล ‘เชื่อมโยง’ ข้อมูลที่อยู่ห่างกันได้ดีกว่า Static Keys

บทสรุป: ทำไมต้อง CASTLE?

Feature	Standard Attention	CASTLE
Autoregressive?	✔ Yes	✔ Yes
Global Context?	✘ Limited (Static)	✔ Rich (Dynamic)
Training Cost?	⚡ $O(L^2)$	⚡ $O(L^2)$
Inference Speed?	🚀 Fast	🚀 Fast
Performance?	Baseline	🏆 Superior

อนาคตของ Language Modeling: Token-Efficient Architecture



เรากำลังมองหาของ High-quality data

- **CASTLE Solution:** เพิ่มประสิทธิภาพต่อ Token (Token-efficiency) ทำให้โมเดลเรียนรู้ได้ฉลาดขึ้นภายใต้ Data Budget เท่าเดิม
- **Impact:** เป็นรากฐานสำคัญสำหรับ LLM ยุคถัดไปที่ต้องการความเข้าใจในระดับ Global

เอกสารอ้างอิงและเครดิต (References)



Primary Paper:

Causal Attention with Lookahead Keys
Zhuoqing Song, Peng Sun, Huizhuo Yuan, Quanquan Gu
ByteDance Seed & Princeton University
September 2025

Contact: quanquan.gu@bytedance.com

Note: Content adapted for presentation format. See full paper (2509.07301v1) for mathematical proofs.