



DeepEyes: ยกระดับ AI ให้ "คิดด้วยภาพ" ผ่าน Reinforcement Learning

การก้าวข้ามข้อจำกัดของโมเดลภาษา-ภาพด้วย
Interleaved Multimodal Chain-of-Thought (iMCoT)


นำเสนอโมเดลขนาด 7B ที่สามารถ "มองเห็น" และ "พิจารณา" ภาพได้เหมือนมนุษย์
โดยไม่ต้องพึ่งพา Supervised Fine-Tuning สำหรับการใช้เครื่องมือ

บทสรุปผู้บริหาร: เมื่อ AI เรียนรู้ที่จะ "เฟื่องพินิจ"



The Breakthrough

DeepEyes เป็นโมเดลแรกที่ใช้ End-to-End Reinforcement Learning (RL) เพื่อเรียนรู้วิธีการใช้เครื่องมือ Zoom-in โดยไม่ต้องมีการสอนล่วงหน้า (Cold-Start SFT)



The Mechanism

ใช้กระบวนการคิดแบบ iMCoT (Interleaved Multimodal Chain-of-Thought) ที่ผสมผสาน "การคิดด้วยข้อความ" และ "การกระทำทางภาพ" (Visual Actions) เข้าด้วยกัน



The Impact

ประสิทธิภาพเพิ่มขึ้น +18.9% บนชุดข้อมูล \$V^*\$ Bench (งานที่ต้องใช้ความละเอียดสูง) และทำคะแนนเหนือกว่าโมเดล Open-source ขนาด 7B ทั่วไป รวมถึงเทียบชั้นกับโมเดล Proprietary ขนาดใหญ่

ปัญหาของการรับรู้แบบเดิม: Passive vs. Active Perception

Passive Perception (VLM ทั่วไป)



- รับภาพเข้ามาเพียงครั้งเดียว (Single Static Input)
- ข้อจำกัด: ข้อมูลสูญหายจากการบีบอัด (Resizing) เมื่อเจอวัตถุเล็กหรือภาพละเอียด
- ผลลัพธ์: "มองเห็น" แต่ "มองไม่ชัด" (Seeing but not Looking)

Active Perception (DeepEyes)



- การรับรู้ของมนุษย์: เรา "กวาดสายตา" (Scan) และ "เพ่งมอง" (Fixate)
- สิ่งที่ DeepEyes ทำ: เลียนแบบพฤติกรรมมนุษย์โดยใช้ Zoom-in Tool
- ผลลัพธ์: เก็บรายละเอียดที่ขาดหายไปได้ครบถ้วน

ทางออกใหม่: DeepEyes & iMCoT Architecture



โมเดลทำหน้าที่เป็น Agent ที่ตัดสินใจเองว่า "เมื่อไหร่" และ "ตรงไหน" ที่ควรจะชมดูภาพ โดยไม่มีใครเขียนกฎบังคับ

กระบวนการเรียนรู้: จากการสุ่มสู่ความเชี่ยวชาญ

Core Technology

End-to-End Reinforcement Learning (RL)

Using GRPO (Group Relative Policy Optimization)

Trial and Error



No Cold-Start

- แตกต่างจาก Agent ทั่วไปที่ต้องเทรนแยก (SFT)
- DeepEyes เริ่มต้นจากศูนย์ (Zero knowledge)
- ค้นพบประโยชน์ของเครื่องมือผ่าน Trial and Error

ลดต้นทุนในการเตรียมข้อมูลสอน (Annotation Cost) และเพิ่มความยืดหยุ่นให้โมเดล

การออกแบบระบบรางวัล (Reward Engineering)

$$R_{total} = R_{acc} + R_{format} + (\text{Indicator} \times R_{tool})$$

R_{acc}

Accuracy Reward:

ให้คะแนนเมื่อตอบถูก

R_{format}

Format Reward:


ให้คะแนนเมื่อตอบ
ถูกรูปแบบ

R_{tool} (The Secret Sauce)

Conditional Tool Reward


- เงื่อนไขสำคัญ: ได้รับโบนัสจากการใช้เครื่องมือ
ก็ต่อเมื่อคำตอบสุดท้ายถูกต้องเท่านั้น
- ผลลัพธ์: ป้องกันพฤติกรรม "Tool Spamming"
และส่งเสริมการใช้เครื่องมืออย่างมีประสิทธิภาพ

ยุทธศาสตร์ด้านข้อมูล (Data Strategy)




**Fine-Grained Perception
(\$V* Dataset)**

ภาพความละเอียดสูง/วัตถุเล็ก



**Charts & Diagrams
(ArxivQA)**

กราฟและแผนภูมิวิทยาศาสตร์




**Reasoning
(ThinkLite-VL)**

โจทย์คณิตศาสตร์และตรรกะ

Data Selection Logic

ใช้โมเดล Qwen2.5-VL คัดกรองเฉพาะโจทย์ที่ 'การใช้เครื่องมือช่วยให้ตอบถูกขึ้นจริง' (Tool Effectiveness)
ตัดข้อที่ง่ายหรือยากเกินไปออก

พัฒนาการของการเรียนรู้ (Training Dynamics)



พฤติกรรมที่เกิดขึ้นเอง: การค้นหาด้วยภาพ (Visual Search)

Question: ชุดดำน้ำนี้เปียกอยู่หรือไม่?



ดูจากภาพกว้างไม่ชัดเจน...
ต้องดูใกล้ๆ

Action: Zoom In



Observation





เห็นรายละเอียดเนื้อผ้าและการสะท้อนแสง

Answer: ใช่ ชุดเปียกอยู่


โมเดลเรียนรู้ที่จะ "เดินเข้าไปดูใกล้ๆ" เพื่อยืนยันสมมติฐาน แทนที่จะเดาจากระยะไกล

พฤติกรรมที่เกิดขึ้นเอง: การเปรียบเทียบข้อมูล (Visual Comparison)

กราฟช่วงไหนมีความแปรปรวนน้อยที่สุด?



Zoom Graph A $\rightarrow$ พันพวนสูง




Zoom Graph C $\rightarrow$ เส้นเรียบกว่า

เปรียบเทียบใน
Memory

Answer
กราฟ (c)

โมเดลแสดงพฤติกรรม Multi-step Reasoning โดยการรวบรวมข้อมูลจากหลายจุดมาประมวลผลร่วมกัน

ผลลัพธ์การทดสอบ: ความเป็นเลิศในภาพความละเอียดสูง



พิสูจน์ว่า 'วิธีการมอง' (Active Perception) สำคัญพอๆ กับขนาดโมเดล

ผลลัพธ์ต่อเนื่อง: การระบุตำแหน่งและการลดข้อผิดพลาด



Visual Grounding (RefCOCO)

ระบุตำแหน่งวัตถุได้แม่นยำขึ้น
เพราะโมเดลคุ้นเคยกับการหา
พิกัด (Bounding Box)



Hallucination Mitigation (POPE)

ลดการ 'มั่ว' ข้อมูล
โมเดลเลือกที่จะ 'ซุ่มดู'
เมื่อไม่แน่ใจ แทนที่จะเดา



Math & Reasoning (MathVista)

คะแนน MathVista เพิ่มขึ้น
(No Catastrophic Forgetting)
การฝึก Vision ไม่ได้ทำลาย Logic

เจาะลึกปัจจัยความสำเร็จ (Ablation Studies)

No Tool Reward IBM Plex Mono	โมเดลเลิกใช้เครื่องมือทันที (Lazy)	
Unconditional Reward IBM Plex Mono	โมเดลใช้เครื่องมือมั่วซั่ว (Spamming)	
Conditional Reward (DeepEyes)	ใช้เมื่อจำเป็นเท่านั้น (Smart Usage)	

Data Mix Impact

การใช้ข้อมูลผสม (Perception + Charts + Reasoning) ให้ผลลัพธ์ที่ดีที่สุด
หากใช้ Perception อย่างเดียว ความสามารถ Reasoning จะลดลง

ข้อจำกัดและก้าวต่อไป (Limitations & Future Work)

Current Limitations

- **Base Model Constraints:** ขนาด 7B ยังจำกัดเรื่อง Complex Reasoning
- **Shortcut Learning:** บางครั้งยังใช้วิธีเดา หรือระบุตำแหน่งผิดพลาด เคลื่อนในภาพซับซ้อน

Future Direction

- **Scaling Up:** ขยายผลไปสู่โมเดล ขนาดใหญ่กว่า 7B
- **New Tools:** พัฒนาเครื่องมือเพิ่มเติม เช่น การเลื่อนภาพ (Scrolling) หรือหมุนภาพ

บทสรุป: สื่อนาครตที่ AI "ตื่นรู้" ทางการมองเห็น



- 1. **DeepEyes** ใช้ RL สร้างพฤติกรรมสม Agentic โดยไม่ต้องสอนทีละขั้นตอน
- 2. **Active Perception** คือกฎแฉสำคัญสำหรับภาพความละเอียดสูง
- 3. **Human-Like Behavior** (ค้นหา/เปรียบเทียบ) เกิดขึ้นเองตามธรรมชาติ

เรากำลังก้าวเข้าสู่ยุคที่ AI ไม่ได้แค่**มองเห็น**สิ่งที่อยู่ตรงหน้า แต่มีความพยายามที่จะ **"เข้าใจ"** สิ่งที่เห็นอย่างแท้จริง