


Gated Attention for Large Language Models

การเสริมความไม่เป็นเชิงเส้น ความเบาบาง
และการกำจัด Attention Sinks



บทสรุปผู้บริหาร: เส้นทางผ่านที่เรียบง่าย แต่ทรงพลัง


งานวิจัยนี้นำเสนอการเพิ่ม Sigmoid gate แบบเฉพาะเจาะจงหลังการคำนวณ Scaled Dot-Product Attention (SDPA) ซึ่งเป็นการเปลี่ยนแปลงเล็กน้อยที่ส่งผลลัพท์มหาศาลต่อประสิทธิภาพของโมเดลภาษาขนาดใหญ่



สเกลการทดลอง: ทดสอบกับ
โมเดล 1.7B Dense และ 15B
Mixture-of-Experts (MoE)




ข้อมูลมหาศาล: เทรนด้วยข้อมูล
ขนาด 3.5 ล้านล้านโทเคน



ผลลัพธ์สำคัญ: เพิ่มเสถียรภาพ
ในการเทรน, ขยายขนาดได้ดีขึ้น,
และกำจัดปัญหา Attention Sinks

จุดจบที่หายไปในวิวัฒนาการของ Transformer

LSTMs & GRUs



Gating is core

Highway Networks




Gating for depth

State Space Models




Modern Gating



Transformer
(Softmax Attention)


ในขณะที่กลไก Gating ถูกใช้อย่างแพร่หลายใน Deep Learning ตั้งแต่อดีตจนถึงปัจจุบัน แต่ผลกระทบของมันต่อ Softmax Attention ใน Transformer กลับไม่เคยถูกศึกษาอย่างเป็นระบบ เราจึงตั้งคำถามว่า Softmax Attention กำลังขาดกลไกควบคุมที่สำคัญไปหรือไม่?

ความเข้มข้นของการทดลอง: 30 ตัวแปร กับ 3.5 ล้านล้านโทเคน



เราทำการเปรียบเทียบตัวแปร Attention ถึง 30 รูปแบบ และเทรนโมเดลทุกตัวใหม่ตั้งแต่ต้นด้วยข้อมูล 3.5 ล้านล้านโทเคน เพื่อให้มั่นใจว่าผลลัพธ์ที่ได้มีความน่าเชื่อถือทางสถิติสูงสุด


นวัตกรรม: Gated Scaled Dot-Product Attention



$$\text{Output} = \text{SDPA}(Q, K, V) * \text{Sigmoid}(\text{Gate_Head})$$


เราเพิ่มฟังก์ชัน Sigmoid แบบเฉพาะเจาะจงสำหรับแต่ละ Head (Head-specific) ทันทีหลังการคำนวณ Attention เพื่อควบคุมผลลัพธ์ด้วย Gating Score ที่เรียนรู้ได้

เสถียรภาพและความทนทานทางวิศวกรรม



- **High LR Tolerance:** Gated Attention รองรับ Learning Rate ที่สูงกว่าได้โดยไม่เกิดการ Diverge
- **Convergence:** ช่วยให้โมเดลเข้าสู่จุดที่เหมาะสมได้รวดเร็วและเสถียรมากกว่าในช่วง Pre-training

คุณสมบัติการขยายขนาด: ออกแบบมาเพื่อโมเดลขนาดใหญ่



ประสิทธิภาพที่เพิ่มขึ้นไม่ได้ลดน้อยลง
เมื่อโมเดลมีขนาดใหญ่ขึ้น (Scale Up)
ซึ่งยืนยันได้ว่า Gated Attention เป็น
ทางเลือกสถาปัตยกรรมที่เหมาะสม
สำหรับ LLM ยุคถัดไปที่มีขนาดมหึมา



ปรากฏการณ์ Attention Sink คืออะไร



ใน Transformer ทั่วไป โมเดลมีแนวโน้มที่จะ
เกาะแบบ Attention ไปที่ Token แรกสุด
เพื่อใช้เป็นจุดยึดเหนี่ยว (Safety Anchor)
เมื่อไม่พบข้อมูลที่สำคัญในตำแหน่งอื่น


ปัญหา: สิ่งนี้ทำให้สูญเสียพื้นที่ความจำ
(Capacity) และทำให้การจัดการ Context
ยาว ๆ หรือการทำ Streaming มีปัญหา

การแก้ไขปัญหา Attention Sink อย่างเป็นธรรมชาติ




Gated Attention ใช้กลไกความเบาบาง (Sparsity) ในการ ‘ปิด’ Head ที่ไม่จำเป็น ทำให้โมเดลไม่ต้องเทคะแนนไปที่ Token แรก ผลลัพธ์คือ Attention map ที่กระจายตัวตามความหมายจริงของข้อมูล

ปลดล็อกประสิทธิภาพในบริบทระยะยาว




เนื่องจากโมเดลไม่ได้ยึดติดกับ Start Token (Sink-free) จึงสามารถจัดการกับความยาวข้อความที่เกินกว่าที่เคยเทรนมา (Extrapolation) ได้อย่างมีประสิทธิภาพ และรองรับการทำ Streaming ได้ดียิ่งขึ้น

กลไกที่ 1: การเพิ่มความไม่เป็นเชิงเส้น (Non-Linearity)



Softmax attention ที่ไปเปรียบเสมือนการทำ Low-rank mapping การเพิ่ม Sigmoid gate เข้าไปช่วยสร้างความไม่เป็นเชิงเส้น (Non-linearity) หลังการคำนวณ ทำให้โมเดลมีความสามารถในการเรียนรู้ฟีเจอร์ที่ซับซ้อนได้ดียิ่งขึ้น

กลไกที่ 2: ความเบาบางแบบขึ้นกับ Query (Sparsity)




Gate ทำหน้าที่เป็นตัวกรองสัญญาณรบกวน โดยจะคำนวณคะแนนความสำคัญจาก Query ปัจจุบัน เพื่อลดทอน (Suppress) ข้อมูลจาก Head ที่ไม่เกี่ยวข้อง ทำให้เหลือเฉพาะ**สัญญาณที่ชัดเจนและเป็นประโยชน์ (Sparsity)**

การวิเคราะห์เปรียบเทียบกับตัวแปรอื่น

Variant Name	Complexity	Performance
Standard Softmax	Low	Baseline
Pre-Softmax Gating	Medium	Low Gain
Complex Gating (GRU-style)	High	Moderate Gain
Post-SDPA Sigmoid (Ours)	Low	Best Performance

จากการทดสอบตำแหน่งการวาง Gate และฟังก์ชันต่างๆ (เช่น Pre-softmax หรือ Tanh) เราพบว่าการวาง Sigmoid ไว้หลัง SDPA (Post-SDPA) ให้ผลลัพธ์ที่ดีที่สุด แม้จะมีโครงสร้างที่เรียบง่ายที่สุดก็ตาม

บทสรุปและมุมมองในอนาคต



- Simple & Effective: Gated Attention เป็นการอัปเดตที่เรียบง่ายแต่ทรงพลังสำหรับ Transformer
- Robust: เพิ่มเสถียรภาพ รองรับ Scale ใหญ่ และกำจัดปัญหา Attention Sink
- Mechanisms: ทำงานผ่านการเพิ่ม Non-linearity และ Induced Sparsity
- Future Standard: สถาปัตยกรรมนี้มีศักยภาพสูงที่จะกลายเป็นมาตรฐานใหม่สำหรับ LLM ในอนาคต


เอกสารอ้างอิงและแหล่งข้อมูล



Paper: arXiv:2505.06708

Authors: Zihan Qiu, Zekun Wang, Bo Zheng, et al.

Read Paper



Code & Models

Available on GitHub & HuggingFace

View Code

