

Google DeepMind

Gemini

Gemini Embedding: โมเดล Embedding แบบ Generalizable ประสิทธิภาพสูงจาก Google

ยกระดับการเรียนรู้ Representation Learning ด้วยข้อมูลพลังจาก Gemini

รายงานทางเทคนิค — มีนาคม 2025

มาตรฐานใหม่แห่งวงการ: อันดับ #1 บนกระดานผู้นำ MTEB

68.32

↑ +5.09


เหนือคู่แข่งอันดับสอง

MTEB (Multilingual) Score

- **ประสิทธิภาพสูงสุด (State-of-the-Art):**
ครองอันดับ 1 ในการจัดอันดับ MTEB ทั้งหมด Multilingual, English และ Code
- **ความสามารถรอบด้าน:** รองรับกว่า 100 ภาษา และงานที่หลากหลาย (Retrieval, Clustering, Classification)
- **นวัตกรรม:** ใช้เทคนิคการเทรนแบบ 2-Stage และ Model Soup เพื่อการปรับตัวที่เหนือกว่า

MTEB: Massive Multilingual Text Embedding Benchmark
ครอบคลุม 100+ tasks และ 250+ ภาษา

จากโมเดลภาษาขนาดใหญ่ สู่ Embedding ที่ทรงพลัง



การเริ่มต้น (Initialization)

โมเดลไม่ได้เริ่มเรียนรู้จากศูนย์ แต่ถูก initialize ด้วย parameters ของ Gemini (Decoder-based)


ข้อได้เปรียบ

สืบทอดความสามารถในการเข้าใจ **ภาษา** (Multilingual) และโค้ด (Code Understanding) ของ Gemini มาโดยตรง

ผลลัพธ์

เปรียบเสมือนการ 'Pre-training' โมเดลมาแล้วอย่างเข้มข้น ทำให้มีความรู้พื้นฐาน**แน่น**ก่อนเริ่มงาน**เฉพาะทาง**


สถาปัตยกรรม: Transformer + Mean Pooling



- **Backbone:** ใช้ Transformer ที่มีความสามารถ Bidirectional Attention (ปรับจูนจาก Gemini)
- **Vectorization:** ใช้เทคนิค Mean Pooling (หาค่าเฉลี่ยของ token embeddings ทั้งหมดใน sequence)
- **Dimension:** Output embedding มีขนาด 3,072 dimensions (รองรับ Matryoshka Learning เพื่อลดขนาดได้)
- **Context Window:** รองรับ input text ที่มีความยาวและซับซ้อน


การสังเคราะห์ข้อมูล (Synthetic Data Generation) ด้วย Gemini

เนื่องจากข้อมูลคุณภาพสูงสำหรับการเทรน Embedding มีจำกัด ทีมวิจัยจึงใช้ Gemini เพื่อสร้างข้อมูลสังเคราะห์ขึ้นมาเอง




การคัดกรองคุณภาพและ Hard Negative Mining

Quality Filter



ใช้ Gemini ตรวจสอบความถูกต้องของคู่ (Query, Positive Target) และลบข้อมูลขยะ

Hard Negative Mining




ค้นหาเอกสารที่มีความคล้ายคลึงสูง (Semantically similar) แต่ไม่ใช่คำตอบที่แท้จริง โดยใช้ Gemini ให้คะแนนความเกี่ยวข้อง (Relevance Score)

กระบวนการเทรนแบบ 2-Stage และ Model Soup



Input: Web Corpus
(Title-Passage pairs)

Detail: Large batch size,
Contrastive loss



ปรับเปลี่ยนจาก Text Generation
เป็น Encoding
เป็น Encoding


Input: Human-labeled +
Synthetic Data

Detail: Smaller batch size,
Hard Negative mining




Google Sans fonts (#202124)
เพิ่มความแม่นยำในงานเฉพาะทาง

Technique:
Parameter Averaging



Google brand chatkports (#202124)
นำ checkpoints มารวมกันเพื่อการใช้งาน
ทั่วไป (Generalization) ที่ดีที่สุด

ผลลัพธ์อันดับ 1 บนกระดานผู้นำ MTEB (Multilingual)



ทิ้งห่างคู่แข่งอันดับสองถึง **+5.09 คะแนน**
โดยมีจุดเด่นสำคัญในงานประเภท Classification (**+9.6**) และ Retrieval (**+9.0**)

ความเป็นเลิศในภาษาอังกฤษและงานเขียนโค้ด (Code)

MTEB (English)




Rank 1

73.30

ชนะโมเดลคู่แข่งในงาน Clustering
และ Reranking อย่างชัดเจน

MTEB (Code)



Rank 1

74.66

ทดสอบกับ 8 tasks รวมถึง
StackOverflowQA และ CodeSearchNet

รองรับ use cases ทางเทคนิค เช่น Code Retrieval และ Semantic Code Search ได้อย่างมีประสิทธิภาพสูงสุด

ประสิทธิภาพข้ามภาษา (Cross-Lingual Retrieval)

การค้นหาคำตอบภาษาอังกฤษ ด้วยคำถามภาษาท้องถิ่น (เช่น ฮินดี, เบงกาลี, หรือไทย)



โมเดลสามารถจับใจความสำคัญ (Semantic Meaning) ได้แม้จะเป็นภาษาที่มีทรัพยากรน้อย (Low-resource languages) โดยไม่ต้องใช้ Translation layer แยกต่างหาก

ตัวอย่างการใช้งานจริง: ค้นหาข้ามกำแพงภาษา

Chat Cards

ค้นหาภาษาอัสสัม (Assamese Query)

মেহেন্জো-দোবা সভ্যতা কান নদীৰ দ্বাৰা আৱদ্ধ
আছিল?

(อารยธรรม Mohenjo-Daro ถูกล้อมรอบด้วยแม่น้ำสายใด?)

Gemini Result

...Mohenjo-daro is located west of the Indus River...

Competitor (text-embedding-3-large)

...Mymensingh stands on the bank of the Old
Brahmaputra...

Chat Cards

ค้นหาภาษาฮินดี (Hindi Query with Typo)

आंध्र प्रदेश की राजकीय पक्षी कोसी है?


(นกประจำรัฐ Andhra Pradesh คืออะไร?)

Gemini Result

The Indian roller is the state bird of Andhra Pradesh.

Gemini Embedding เข้าใจบริบทและ Entities แม้คำถามจะมีคำผิด (Typo) หรือเป็นภาษาท้องถิ่น

ทำไมข้อมูลสังเคราะห์ (Synthetic Data) ถึงสำคัญ?



Without Synthetic: คะแนนเฉลี่ย 57.57
With Synthetic: คะแนนเฉลี่ย 75.17

Conclusion: การใช้ Gemini สร้าง Training Data ช่วยลด Bias และเพิ่มความครอบคลุมของข้อมูล (Coverage) อย่างมหาศาล โดยเฉพาะในงาน Classification

ข้อมูลจำเพาะทางเทคนิคและการใช้งาน

	Standard Dimension	3,072 dimensions (High precision)
	Matryoshka Representation Learning (MRL)	รองรับการตัดทอน ขนาดเหลือ 1,536 หรือ 768 dimensions โดยยังคงประสิทธิภาพสูง
	Inference Efficiency	ช่วยประหยัดพื้นที่จัดเก็บและเพิ่มความเร็วในการค้นหา (Retrieval speed)
	API Availability	ใช้งานได้ผ่าน Google AI Studio / Gemini API

บทสรุป: อนาคตของ Embedding อยู่ที่นี่




Unified Model

โมเดลเดียวรองรับ Text, Code, และ 100+ ภาษา



Gemini Powered

ขับเคลื่อนด้วย Data และ Architecture ของ Gemini



Production Ready

รองรับงานจริงทั้ง RAG, Search, และ Classification

‘Generalizable Embeddings from Gemini’ — การผสานรวมที่ลงตัวระหว่างประสิทธิภาพระดับ SOTA และความยืดหยุ่นในการใช้งานจริง

ศึกษาเพิ่มเติมที่ <https://ai.google.dev/gemini-api/docs/embeddings>