



Kimi-VL: ประสิทธิภาพเหนือระดับในโลก **Multimodal AI**

โมเดล **Open-Source** สถาปัตยกรรม **MoE** กับพารามิเตอร์ใช้งานจริง
เพียง **2.8 พันล้าน** (2.8B Activated Parameters)

การผสานรวมที่ลงตัวของ **‘Smart’, ‘Long’** และ **‘Clear’**

ประสิทธิภาพระดับเรือธง โดยไม่ต้องใช้ทรัพยากรระดับมหาศาล



2.8B

Activated Parameters (จาก 16B Total)

- **Context Window:** รองรับบริบทความยาวถึง 128k tokens
- **Visual:** รองรับ Native Resolution (MoonViT)
- **Performance:** เปรียบเทียบ GPT-4o-mini และ Qwen2.5-VL-7B ในหลายเกณฑ์วัดผล

ประสิทธิภาพ (จากเกณฑ์วัดผล)



สถาปัตยกรรม: การผสานพลังของ MoonViT และ Moonlight MoE



Vision (MoonViT):

Vision Encoder ความละเอียดดั้งเดิม
ขนาด 400M พารามิเตอร์
ไม่มีการแบ่งภาพเป็นส่วนย่อย

Bridge (MLP Projector):

ใช้ MLP 2 ชั้น เพื่อเชื่อมต่อ
Vision Features เข้ากับ LLM

Language (Moonlight MoE):

โมเดลภาษาแบบ Mixture-of-Experts
ที่มีพารามิเตอร์ใช้งานจริงเพียง 2.8B

Pillar 1: 'Clear' – การรับรู้ภาพที่ชัดเจนด้วย Native Resolution

MoonViT ประมวลผลภาพที่ความละเอียดและอัตราส่วนภาพ (Aspect Ratio) ที่แตกต่างกันโดยธรรมชาติ โดยใช้ 2D Rotary Positional Embedding (RoPE) เพื่อระบุตำแหน่งข้อมูลภาพอย่างแม่นยำ

รองรับพิกเซลสูงสุดถึง 3.2 ล้านพิกเซล โดยไม่ต้องตัดต่อภาพ (Patching/Splitting) ทำให้เห็นรายละเอียดเล็กๆ ได้ชัดเจน

InfoVQA:

83.2%

ScreenSpot-Pro:


34.5%

Sparkling Smiles Clinic Ratio Analysis						
Ratio	Formula	2010	2020	2021	2022	Industry Average
Liquidity Ratios						
Liquidity Ratio	Formula = Aqulty Ratio	1.4%	1.8%	1.8%	1.2%	2.4%
Liquidity Ratio	Formula = Liquidity	2.9%	2.8%	1.3%	2.8%	3.8%
Liquidity Ratio	Formula = Asset lhpumat Ratio	1.6%	1.8%	1.2%	1.6%	3.3%
Liquidity Assomed Ratio	Formula = Deronred	17.6%	18.3%	16.8%	15.6%	2.7%
Liquidity lrmmeramsoot Financial Ratio	Formula = Reconsad Ratio	8.3%	8.8%	6.3%	6.6%	2.1%
Asset Management Ratios						
Asset Ratio	Formula = Liquidity	40.5%	54.4%	86.8%	22.2%	3.7%
Asset Management Ratios	Formula = Asset Daysmed Dissted	10.2%	18.9%	15.7%	23.7%	1.8%
Asset lthawos Ratio	Formula = Asset Asset	9.7%	15.2%	18.0%	18.5%	1.8%
Asset Management Rew Ratio	Formula = Asset	6.5%	8.6%	6.0%	6.6%	1.6%
Asset Management Ratio	Formula = Real Asset	3.3%	3.0%	3.7%	3.6%	0.2%
Asset Raperience Ratio	Formula = Conterence lrrlOia.asset	38.4%	30.8%	38.8%	36.0%	2.2%
Solvency Ratios						
Solvency Ratio	Formula = GMERNT Ebaosid	31.7%	25.7%	64.5%	45.5%	5.5%
Solvency Ratio	Formula = SNO8ndnvelcat	5.6%	5.7%	9.8%	5.2%	3.6%
Comerser Solvency Ratio	Formula = LSMB Asset	5.6%	8.8%	5.8%	5.7%	1.9%
Solvency Ratio	Formula = Underssinettlvent Ratio	27.5%	30.2%	28.7%	26.8%	2.7%
Profitability Ratios						
Profitability Ratios	Formula = lbnoset	13.3%	10.1%	6.7%	10.6%	3.7%
Profitability Ratios	Formula = lncove	11.3%	16.7%	14.3%	13.7%	4.5%
Business Ratio	Formula = Fixals	10.3%	12.5%	21.2%	20.4%	3.4%
Resstlssn hiteome Ratio	Formula = Weirbuna	8.4%	3.5%	6.2%	3.6%	0.7%
Penltlone Medls Ratio	Formula = Ganns	8.3%	3.8%	6.3%	6.8%	6.7%


Pillar 2: 'Long' - รองรับบริบทข้อมูลขนาดใหญ่ถึง 128K

- Needle-in-a-Haystack: ความแม่นยำในการค้นหาข้อมูล (Recall) เกือบ 100% ในบริบท 128k ทั้งในรูปแบบข้อความและวิดีโอ
- Use Cases: วิเคราะห์วิดีโอความยาว 1 ชั่วโมง หรือเอกสารมากกว่า 100 หน้าได้ในการป้อนข้อมูลครั้งเดียว

Video-MME



MMLongBench-Doc



Pillar 3: ‘Smart’ - ความฉลาดในการให้เหตุผลทางคณิตศาสตร์

แม้จะมีขนาดเล็ก แต่ Kimi-VL สามารถแก้ไขโจทย์คณิตศาสตร์และตรรกะที่ซับซ้อนได้ดีเยี่ยม แข่งขันได้กับโมเดลที่มีความหนาแน่น (Dense models) ขนาดใหญ่กว่า

Metric	Kimi-VL-A3B	GPT-4o	Qwen2.5-VL-7B
MathVista (Pass@1)	68.7%	63.8%	68.2%
MMMU (Val)	57.0%	N/A	58.6%

ขั้นตอนการฝึกฝน (Training Pipeline) ที่แม่นยำ 5 ระยะ



ขั้นตอน 'Cooldown' คือกุญแจสำคัญที่ใช้ข้อมูลสังเคราะห์คุณภาพสูงเพื่อเพิ่มความแม่นยำ

กลยุทธ์การสร้างข้อมูล: หลากหลายและคุณภาพสูง

Interleaving Data: ข้อมูลภาพสลับข้อความ
ช่วยรักษาความสามารถทางภาษา


Agent Data: ข้อมูล Screenshot และ Action Space สำหรับการใช้งาน GUI

OCR Data: ข้อมูลทั้งแบบ Synthetic และ Real-world รวมถึงลายมือและตาราง

Synthetic Caption: คำบรรยายภาพที่สร้างขึ้น เพื่อเพิ่มความละเอียด

ก้าวไปอีกขั้นกับ Kimi-VL-Thinking

เพิ่มระบบการคิดแบบ 'System 2' ให้กับ Vision-Language Model



- **Long Chain-of-Thought (CoT) SFT:** การปรับแต่งด้วยข้อมูลกระบวนการคิดที่ยาวและซับซ้อน
- **Reinforcement Learning (RL):** การเรียนรู้แบบเสริมกำลังเพื่อสอนให้โมเดล 'วางแผน' และ 'ตรวจสอบตัวเอง'

กระบวนการฝึกฝนระบบการคิด (RL Training)

Online RL: อัปเดตโมเดลแบบวนซ้ำ
(Iterative updates)

Exploration
(สำรวจ)

Planning
(วางแผน)


Evaluation
(ประเมิน)

Reflection
(ไตร่ตรอง)


Length Penalty:
บทลงโทษเพื่อป้องกันการคิด
วนซ้ำที่ยาวเกินความจำเป็น

Curriculum Sampling:
เลือกโจทย์ตามระดับความ
ยากเพื่อให้โมเดลเรียนรู้
เป็นลำดับขั้น

ผลลัพธ์จากการ 'คิด' บนเกณฑ์วัดผล MathVision




กรณีศึกษา 1: การอนุมานจากเอกสารลายมือเขียน (Manuscript Deciphering)



"The manuscripts belong to Albert Einstein... based on handwriting style, content analysis, and language cues."

โมเดลวิเคราะห์สไตน์การเขียน,
สัญลักษณ์ทางคณิตศาสตร์ (Tensor
calculus), และภาษาเยอรมัน
เพื่อระบุว่านี่คือต้นฉบับงานวิจัย
'General Relativity' ของ Albert
Einstein

กรณีศึกษา 2: AI Agent และการนำทางบนหน้าจอ (GUI Navigation)



- 1. **See:** มองเห็นองค์ประกอบบนหน้าจอ (Settings menu)
- 2. **Plan:** วางแผนลำดับขั้นตอน (คลิกเมนู -> Settings -> Privacy)
- 3. **Act:** สั่งการคลิกและเลื่อนหน้าจอ (Scroll/Click) จนสำเร็จภารกิจ

OSWorld Pass@1:
8.22% (ชนะ GPT-4o)

กรณีศึกษา 3: ความเข้าใจวิดีโอขนาดใหญ่ (Long Video Understanding)



Scene Segmentation:
แบ่งฉากวิดีโอตามเนื้อหา
ได้อย่างแม่นยำ

Timestamping:
ระบุเวลาเริ่ม-จบของ
แต่ละเหตุการณ์

Detailed Description:
บรรยายรายละเอียด
(เช่น การปีนเขา, กองล้อมแนต)

บทสรุป: มาตรฐานใหม่ของ Multimodal AI ที่ทรงพลังและประหยัด

- ✓ **Efficient:** 2.8B Activated Parameters ประหยัดทรัพยากร
- ✓ **Capable:** ครอบคลุมทั้ง Smart (Reasoning), Long (128k), และ Clear (Native Res)
- ✓ **Advanced:** ระบบ Thinking ที่ยกระดับการแก้ปัญหาซับซ้อน

Open Source: Code และ Model เผยแพร่สู่สาธารณะแล้ว

Link: <https://github.com/MoonshotAI/Kimi-VL>

