

ขอแนะนำ Llama 3: มาตรฐานใหม่ของโมเดลภาษา ขนาดใหญ่จำเอนมีนระดับโลก

จากการทดลองสู่ความเชี่ยวชาญทางวิศวกรรม:
เปิดตัวโมเดลรุ่น 8B, 70B และรุ่นเรือธง 405B




The Herd: การเปิดตัวชุดโมเดลภาษา (Foundation Models) ที่ครอบคลุมทุกการใช้งาน ตั้งแต่ระดับอุปกรณ์ (Edge) ไปจนถึงระดับคลาวด์ (Cloud)




Open SOTA: โมเดล 405B คือโมเดลแบบ Open Weights ตัวแรกที่มีประสิทธิภาพทัดเทียมกับโมเดลระดับท็อปอย่าง GPT-4



Capabilities: รองรับหลายภาษา (Multilingual), การเขียนโค้ด (Coding), การใช้เหตุผล (Reasoning) และการใช้เครื่องมือ (Tool Usage) ตั้งแต่เริ่มต้น



สมาชิกในฝูง Llama 3: ประสิทธิภาพสูงสุดในทุกขนาด



Llama 3 8B

ประสิทธิภาพสูงบนอุปกรณ์ขนาดเล็ก (Edge Devices) ด้วยความเร็วในการประมวลผลที่เหนือกว่า

Llama 3 70B


โมเดลเนกประสงค์ที่มีความสมดุลระหว่างประสิทธิภาพและความคุ้มค่าในการใช้งาน (Inference Cost)

Llama 3 405B (Flagship)


โมเดลเรือธงขนาด **405 พันล้าน** พารามิเตอร์ เทรนด้วยโทเคนกว่า **15.6 ล้านล้าน** ตัว

The Teacher-Student Synergy: การค้นพบสำคัญ — โมเดล 405B ถูกใช้**สร้างข้อมูลสังเคราะห์** (Synthetic Data) คุณภาพสูงเพื่อสอนโมเดลขนาดเล็ก ทำให้ประสิทธิภาพของทั้งฝูงสูงกว่าคู่แข่งในขนาดเดียวกัน

ปรัชญาการสร้างโมเดล: 3 ปัจจัยหลักสู่ความฉลาดระดับ AGI




Data is Destiny: ข้อมูลคือหัวใจของความฉลาด




สถาปัตยกรรมและการขยายขนาด (Architecture & Scaling Laws)

Dense Transformer Architecture

- เลือกใช้สถาปัตยกรรมมาตรฐานแต่ปรับปรุงประสิทธิภาพ (GQA, RoPE Base Frequency 500,000)
- **128K Token Vocabulary**: เพิ่มประสิทธิภาพการบีบอัดข้อความ ทำให้โมเดล 'อ่าน' ข้อมูลได้มากขึ้นในเวลาเท่าเดิม
- **Compute-Optimal**: กฎการขยายขนาด (Scaling Laws) ช่วยให้ทีมวิศวกรสามารถทำนายประสิทธิภาพของโมเดล 405B ได้อย่างแม่นยำตั้งแต่ก่อนเริ่มเทรนจริง
- **Context Window**: รองรับบริบทความยาวถึง 128K Tokens



วิศวกรรมระดับโลก: โครงสร้างพื้นฐานและการขนานแบบ 4 มิติ (4D Parallelism)




Hardware Scale:

เทรนบน **GPU NVIDIA H100**
จำนวน 16,000 ตัว
เชื่อมต่อด้วยเทคโนโลยี **RoCE**
และ **NVLink**

Reliability:

ระบบอัตโนมัติที่แก้ไขปัญหา
Hardware Failure ได้ถึง **90%**
โดยไม่ต้องใช้คนแทรกแซง
ทำให้การเทรนต่อเนื่องยาวนาน
ถึง **54 วัน**

ศิลปะแห่งการขัดเกลา: กระบวนการ Post-Training



- **The Recipe:** การผสมผสานระหว่าง SFT และ DPO หลายรอบ (**Multiple Rounds**) เพื่อปรับแต่งพฤติกรรมของโมเดล
- **Rejection Sampling:** เทคนิคการสุ่มคำตอบจากโมเดลหลายๆ แบบ แล้วเลือกคำตอบที่ดีที่สุดมาใช้สอนโมเดลตัวเองซ้ำ (**Self-Improvement**)
- **Quality over Quantity:** เน้นคัดเลือกข้อมูล SFT และ Preference Data ที่มีคุณภาพสูงสุด โดยผ่านการตรวจทานจากมนุษย์และการกรองด้วยโมเดล

ความเชี่ยวชาญด้านการเขียนโค้ด และการใช้เหตุผล (Code & Reasoning)

- **Expert Training:** แยกเทรน 'Code Expert' ด้วยข้อมูลโค้ดล้วนๆ **1 ล้านล้านโทเคน** เพื่อสร้างความเชี่ยวชาญเฉพาะทาง
- **Execution Feedback:** กระบวนการเรียนรู้จากการลงมือทำ — โมเดลเขียนโค้ด -> **รันโค้ดจริง** -> หาก Errorให้นำผลลัพธ์กลับมาแก้ไขใหม่จนกว่าจะถูกต้อง (Self-Correction)
- **Synthetic Data Translation:** การใช้โมเดลแปลโค้ดจากภาษาหลัก (เช่น Python) ไปเป็นภาษาที่หาข้อมูลได้ยาก (เช่น PHP, Rust) เพื่อเพิ่มความสามารถรอบด้าน
- **Step-by-Step Reasoning:** สอนให้โมเดลคิดเป็นขั้นตอน (**Chain of Thought**) เพื่อแก้โจทย์คณิตศาสตร์ที่ซับซ้อน

```
def gushti_cdi():  
    n = int(input())  
    arr = list(map(int, input().split()))  
    points = 0  
    for i in range(n):  
        if arr[i] == 0 and i != 0:  
            idx = arr.index(max(arr[i:]))  
            points += arr[idx]  
            arr[idx] = 0  
    return points  
  
for _ in range(int(input())):  
    print(gushti_cdi())
```

```
<?php  
function gushti_cdi() {  
    $n = (int)fgets(STDIN);  
    $arr = explode(" ", fgets(STDIN));  
    $points = 0;  
    for ($i = 0; $i < $n; $i++) {  
        if ($arr[$i] == 0 && $i != 0) {  
            $maxVal = max(array_slice($arr, 0, $i));  
            $idx = array_search($maxVal, $arr);  
            $points += $arr[$idx];  
            $arr[$idx] = 0;  
        }  
    }  
    return $points;  
}  
  
$t = (int)fgets(STDIN);  
for ($i = 0; $i < $t; $i++) {  
    echo gushti_cdi() . "\n";  
}  
?>
```


จาก Chatbot สู่ Assistant: การใช้เครื่องมือ (Tool Use)

Zero-Shot Tool Use:


โมเดลสามารถเรียนรู้ที่จะ
เรียกใช้เครื่องมือได้เองโดย
ไม่ต้องโอบมีตัวอย่างมาก่อน

Integrated Tools: Search Engine (Brave Search), Python Interpreter, Wolfram Alpha

[illegible]

Agentic Behavior: สามารถวางแผนหลายขั้นตอน (Multi-step planning) เพื่อแก้ปัญหาที่ซับซ้อนได้ ในครั้งเดียว

รองรับบริบทขนาดใหญ่และหลากหลายภาษา (Long Context & Multilingual)




- **128K Context Window:** รองรับข้อมูลนำเข้าขนาดใหญ่เทียบเท่าหนังสือเล่มหนาๆ ได้โดยไม่สูญเสียความแม่นยำ
- **Needle in a Haystack:** ทำคะแนนได้ 100% ในการค้นหาข้อมูลเล็กๆ ที่ซ่อนอยู่ในบริบทขนาดใหญ่ (Needle Retrieval)



- **Multilingual Mastery:** รองรับ 8 ภาษาหลักอย่างเป็นทางการ (อังกฤษ, เยอรมัน, ฝรั่งเศส, อิตาลี, โปรตุเกส, ฮินดี, สเปน และไทย)
- **Training Data:** เพิ่มสัดส่วนข้อมูลภาษาต่างประเทศใน Pre-training เพื่อความเข้าใจในบริบททางวัฒนธรรมและภาษาศาสตร์

Benchmarking the Beast: ประสิทธิภาพเทียบเท่า GPT-4o


โมเดล Open Weights ที่ทรงพลังที่สุดในปัจจุบัน



Benchmark	Llama 3 405B	GPT-4o / GPT-4
MMLU (Knowledge)	88.6	GPT-4: 89.1
GSM8K (Math)	96.8	96.1
HumanEval (Code)	89.0	90.2


Llama 3 405B vs. GPT-4o: ผลการทดสอบ Human Evaluation แสดงให้เห็นประสิทธิภาพที่ ‘สูสี’ (Tie) หรือ ‘ชนะ’ (Win) ในหลายหมวดหมู่ เช่น การเขียนโค้ด (Coding) และการใช้เหตุผล (Reasoning)

Safety by Design: ความปลอดภัยในทุกระดับ



- **Llama Guard 3**: โมเดลความปลอดภัยแยกต่างหาก (**System-level shield**) สำหรับคัดกรอง Input/Output ของผู้ใช้
- **Red Teaming**: การทดสอบเจาะระบบโดยผู้เชี่ยวชาญด้าน **CyberSec** และ **CBRNE** (เคมี/ชีวภาพ) เพื่อหาจุดอ่อนและปิดช่องโหว่
- **CyberSecEval**: ผลการทดสอบยืนยันว่า Llama 3 ไม่ได้เพิ่มความเสี่ยงด้านการโจมตีทางไซเบอร์เมื่อเทียบกับการใช้ Search Engine ทั่วไป

ก้าวต่อไปสู่ Multimodal: การมองเห็นและการได้ยิน



- **Compositional Approach:** การเพิ่มความสามารถใหม่โดยไม่ต้องเทรนโมเดลภาษาใหม่ทั้งหมด แต่ใช้วิธีเชื่อมต่อ 'Adapters' เข้ากับโมเดลเดิม
- **Vision & Video:** การใช้ **Cross-attention** layers เชื่อมต่อ Image Encoder เข้ากับ **Llama 3** ทำให้โมเดล 'เห็น' และ 'เข้าใจ' วิดีโอได้
- **Speech Integration:** รองรับการสั่งงานและโต้ตอบด้วยเสียงอย่างเป็นธรรมชาติ

ผลลัพธ์การทดลองด้านการมองเห็น (Vision Experiments)



Visual Recognition

ระบุวัตถุและเข้าใจบริบทในภาพ
ได้อย่างแม่นยำ



Chart & Document Understanding

ความสามารถในการอ่านกราฟ/
แผนภูมิ และเอกสาร (OCR)
ที่เหนือชั้น




Video Understanding

เข้าใจลำดับเหตุการณ์ในวิดีโอ
ด้วย Temporal Aggregation

Competitive Performance: ผลการทดลองเบื้องต้นชี้ให้เห็นว่าสถาปัตยกรรมแบบ
Compositional ให้ผลลัพธ์ที่ทัดเทียมกับโมเดล State-of-the-Art ด้านรูปภาพและวิดีโอ

พลังแห่ง Open Intelligence อยู่ในมือคุณ



- **Summary:** Llama 3 405B พิสูจน์แล้วว่า Open Weights สามารถเทียบชั้นกับโมเดลที่ดีที่สุดในโลกได้
- **The Ecosystem:** ไม่ใช่แค่โมเดล แต่คือระบบนิเวศ (Llama Guard, Prompt Guard, Executors) ที่พร้อมสำหรับนักพัฒนา

What will you build with the herd?
— มาร่วมสร้างสรรค์นวัตกรรมใหม่ด้วย
รากฐานอัจฉริยะที่เปิดกว้างที่สุดในโลก