


Mamba: The Next Evolution of Sequence Modeling

คลื่นลูกใหม่แห่งวงการ AI


- Beyond Transformers: สถาปัตยกรรมใหม่ที่ไม่พึ่งพา Attention แบบเดิม
- The Best of Both Worlds: ผสานความเร็วของ RNN และความแม่นยำของ CNN
- The Promise: ประมวลผลข้อมูลระดับ Infinite Context ด้วยประสิทธิภาพสูงสุด




The Bottleneck: เมื่อความฉลาดแลกมาด้วยต้นทุน

Quadratic Cost vs. Linear Efficiency

- **The Attention Trap:** Transformers ใช้การคำนวณแบบ Quadratic $O(L^2)$ ยิ่งข้อความยาว การคำนวณยิ่งทวีคูณ
- **Memory Wall:** KV Cache กินหน่วยความจำมหาศาลเมื่อต้องประมวลผล Long Context
- **The Challenge:** เราต้องการความฉลาดระดับ GPT แต่เร็วและเบาเหมือน RNN ($O(L)$)



Enter the State Space: ย้อนกลับสู่รากฐานเพื่อก้าวกระโดด



Continuous Systems

มองข้อมูลเป็นระบบต่อเนื่องทาง
คณิตศาสตร์ (Continuous-time) แล้ว
แปลงเป็น Digital (Discretization)

The Core Equation


$$h'(t) = Ah(t) + Bx(t)$$

สมการหัวใจหลักในการส่งต่อสถานะ
(State Transition)

Compressed Memory

ย่อประวัติข้อมูลทั้งหมดเก็บไว้ใน
Hidden State ขนาดคงที่
ไม่ต้องอ่านข้อมูลเก่าซ้ำ

The 'Selection' Magic: หัวใจสำคัญของความอัจฉริยะ



- **Problem with Old SSMs:**
โมเดลรุ่นเก่าจำทุกอย่างเท่ากันหมด (Linear Time Invariant)
ทำให้ข้อมูลขยะปนกับข้อมูลสำคัญ
- **Selective Mechanism:**
Mamba เพิ่มกลไกให้โมเดล
เลือก ได้ว่าจะ 'จำ' หรือ 'ลืม'
ข้อมูลไหนตามบริบท
- **Dynamic Dynamics:**
ค่าพารามิเตอร์เปลี่ยนแปลงตาม
Input x_t ทำให้โฟกัสเฉพาะสิ่งที่
จำเป็น คล้ายกลไกของ LSTM
แต่เร็วกว่า

Mamba-2 & SSD: ทลายกำแพงด้วย Matrix Multiplication

Structured State Space Duality (SSD)


การค้นพบความเชื่อมโยงทางคณิตศาสตร์ระหว่าง SSMs และ Linear Attention

Matrix Transformation


เปลี่ยนการคำนวณแบบ Recurrent ให้กลายเป็นการคูณ Matrix แบบ Block Decomposition

Hardware Efficiency

ออกแบบมาเพื่อ Tensor Cores บน GPU ยุคใหม่
Train เร็วขึ้น 2-8 เท่า



Speed & Scale: เร็ว แรง ไร้ขีดจำกัด




Massive Throughput

Mamba-2 เร็วกว่าและรองรับ Context ยาวกว่า โดยประสิทธิภาพไม่ตก


- **Linear Time $O(L)$:** เวลาประมวลผลเพิ่มขึ้นเป็นเส้นตรง ไม่ทวิคูณ
- **Constant Inference Cost:** ใช้เวลาคงที่ต่อ 1 คำ ($O(1)$) ไม่ว่าจะคุยมานานแค่ไหน
- **Long Context King:** รองรับ State ขนาดใหญ่ได้ดีเยี่ยม

Hybrid Power: TransMamba และภาระผสานจุดแข็ง



- **The Concept:** ใช้ Transformer เป็น Encoder เพื่อเข้าใจภาพรวม และ Mamba เป็น Decoder เพื่อสร้างคำตอบที่รวดเร็ว
- **Feature Fusion:** เทคนิคการรวม Hidden States จาก Mamba เข้ากับ Features จาก Transformer
- **Result:** ได้ความฉลาดของ Transformer และความเร็วของ Mamba ในโมเดลเดียว

Scaling with BlackMamba: Mixture of Experts (MoE)



Sparse Activation: Only selected experts are used per token.

MoE Architecture

แทนที่ MLP layers เดิมด้วย 'Experts' (ผู้เชี่ยวชาญเฉพาะด้าน) จำนวนมาก

Routing Mechanism

ระบบเลือกใช้งานเฉพาะ Expert ที่จำเป็นต่อ Token นั้นๆ (Active Parameters ต่ำ แม้ Total Parameters สูง)

Performance


BlackMamba ชนะ Transformer
ในขณะที่ใช้ **Training FLOPs** น้อยกว่า

Zamba2: ผู้นำโมเดลขนาดเล็ก (SLM) ยุคใหม่

Model	Size	MMLU Score	HellaSwag Score	Speed
Zamba2-1.2B	1.2B	43.1	70.9	High
Gemma2-2B	2B	32.8	71.4	Medium
Llama3.2-1.2B	1.2B	36.8	63.7	Medium

- **Hybrid Design:** ใช้ Mamba-2 Backbone ผสมกับ Shared Attention Blocks
- **State-of-the-Art:** ชนะโมเดลขนาดใหญ่กว่าอย่าง Gemma และ Llama ในหลาย Benchmark
- **Low Latency:** เหมาะสำหรับการใช้งาน On-device หรือ Edge Computing

Beyond Text: ก้าวต่อไปสู่โลกแห่งข้อมูลหลากหลายมิติ



The Future is Linear: บทสรุปแห่งประสิทธิภาพ

Transformer Era ($O(L^2)$)

Mamba Era ($O(L)$)



Efficiency

ปลดล็อกคอขวดการคำนวณด้วย
Linear Complexity



Capability

รองรับ Infinite Context และ
Multimodal Data อย่างแท้จริง



Vision

กุญแจสำคัญสู่ยุคถัดไปของ AI
ที่ทรงพลังและเข้าถึงได้