




MCP-Universal: การวัดผล Large Language Models ด้วยเชิร์ฟเวอร์ Model Context Protocol ในโลกจริง


เจาะลึกงานวิจัยจาก Salesforce AI Research — สิงหาคม 2025

นำเสนอโดย Ziyang Luo, Zhiqi Shen และคณะ


จาก Chatbots สู่ Agents: ยุคแห่งการเชื่อมต่อ



Isolated LLM



The USB-C of AI



Model Context Protocol (MCP)

คือมาตรฐานใหม่ที่เปรียบเสมือน 'USB-C ของ AI' ช่วยให้ LLM เชื่อมต่อกับแหล่งข้อมูลภายนอกและเครื่องมือต่างๆ ได้อย่างไร้รอยต่อ

สถาปัตยกรรม 3 ชั้น (3-Layer Architecture)

Host (AI App) — Client (Bridge) — Server (Capability Provider)

AI ไม่ได้ทำหน้าที่แค่สร้างข้อความอีกต่อไป แต่กำลังกระทำต่อโลกความจริง

ช่องว่างระหว่าง 'ห้องแล็บ' และ 'โลกความจริง'

เกณฑ์วัดผลปัจจุบัน (Current Benchmarks)	ความท้าทายโลกจริง (Real World Challenges)
 • Simulation (แบบจำลอง)  • Static Data (ข้อมูลคงที่)  • Isolated (ทำงานแยกส่วน) • Example: HumanEval, GSM8k	 • Real-time Data (ข้อมูลเรียลไทม์)  • Authentication (การยืนยันตัวตน)  • Multi-turn Reasoning (การหาเหตุผลหลายขั้นตอน)  • Temporal Dynamics (พลวัตของเวลา)

ข้อจำกัด (Limitations)

- เกณฑ์วัดผลปัจจุบันขาด Temporal Dynamics หรือพลวัตของเวลา
- การทดสอบส่วนใหญ่พึ่งพาการจำลอง (Mock environments) ซึ่งไม่สะท้อนความซับซ้อนของ API จริง
- MCP-RADAR และ MCPWorld ยังมีข้อจำกัดเรื่อง Data Leakage และการพึ่งพา GUI มากเกินไป

ขอแนะนำ MCP-Universe

มาตรฐานแรกที่เกิดผลด้วยเชิร์ฟเวอร์ MCP ของจริง ไม่ใช่แบบจำลอง



โดเมนหลัก
(Core Domains)



เชิร์ฟเวอร์ MCP จริง
(Real Servers)



งานที่แตกต่างกัน
(Unique Tasks)



เครื่องมือที่ใช้งานได้
(Tools)



ครอบคลุมการใช้งานจริงตั้งแต่การนำทาง, การจัดการ Code, การเงิน,
ไปจนถึงการออกแบบ 3D และการค้นหาข้อมูลบนเว็บ

6 โดเมนหลักแห่งการทดสอบ (The 6 Core Testing Domains)



Location Navigation

Google Maps — การนำทางและ
การค้นหาสถานที่จริง



Repository Management

GitHub — การจัดการ Version
Control และ Issue Tracking



Financial Analysis

Yahoo Finance — การวิเคราะห์
หุ้นและข้อมูลตลาดแบบเรียลไทม์




3D Design

Blender — การสร้างโมเดลและ
ปรับแต่งวัตถุ 3 มิติ



Browser Automation

Playwright — การควบคุมบราว
เซอร์เพื่อจองตั๋วหรือเก็บข้อมูล




Web Searching

Google Search — การค้นหา
ข้อมูลแบบ Open-ended


การทำงานบนข้อมูลจริง (Under the Hood: Working with Real Data)

- **Navigation:**
หาเส้นทางจากโรงแรม Sheraton ดุไบ ไปยังร้านอาหารที่มีเรตติ้ง 4.2+ ที่มีระยะขับรถ เท่ากันกับโรงแรม Oryx อามูดาบี
- **Coding:**
แก้ไข Issue ใน GitHub Repository และ ทำการ Commit ผ่าน MCP
- **Finance:**
วิเคราะห์พอร์ตการลงทุนโดยอ้างอิงราคา ตลาด ณ ปัจจุบัน



⚠️ ****Note****: ข้อมูลเปลี่ยนแปลงตามเวลาจริง (Temporally Sensitive) — คำตอบที่ถูกต้องในวันนี้ อาจเปลี่ยนไปในวันพรุ่งนี้

สถาปัตยกรรมการประเมินผล (Evaluation Framework Architecture)



LLM Manager

รองรับโมเดลหลากหลายเช่น
GPT-5, Claude-4.0

Agent Builder

สร้าง Agent ที่มีกลยุทธ์การให้
เหตุผล (ReAct)

Extensible Framework

ออกแบบให้ง่ายต่อการเพิ่ม Agent
หรือ Server ใหม่ๆ ในอนาคต

การวัดผลที่แม่นยำ: **Execution-Based Evaluation**

ทำไมเราถึงไม่ใช่ 'LLM-as-a-judge'

✅ **Format Evaluators**
ตรวจสอบความถูกต้องของรูปแบบข้อมูล (**JSON/Protocol Compliance**) — ส่วนใหญ่ทำได้ดี (>80%)

🛡️ **Static Evaluators**
ตรวจสอบข้อเท็จจริงที่ไม่เปลี่ยนแปลงตามเวลา
(เช่น ประวัติราคาหุ้นในอดีต)

❌ **Dynamic Evaluators**
จุดสำคัญ — ระบบจะดึงข้อมูล Ground Truth ณ เวลาจริง (**Real-time**) เพื่อตรวจสอบความถูกต้องของคำตอบ
(เช่น สภาพอากาศ, ราคาตัวเครื่องบินปัจจุบัน) ❌



กรณีศึกษา: การกิจจุดนัดพบ (Case Study: The Meeting Point Task)



User Query

Find midpoint restaurant between Dubai & Abu Dhabi.




Agent Action

Calls `map_geocode` for both hotels.



Reasoning

Calculates midpoint coordinates.



Search

Calls `search_places` for restaurants rating > 4.2.




Analysis

Calls `distance_matrix` to compare driving times.




Solution

Rasoi Ghar Restaurant identified as best compromise.




Insight: โมเดลต้องมีการวางแผน (Planning), การใช้เครื่องมือ (Tool Use), และการคำนวณ (Calculation) ในกระบวนการเดียว

ผลลัพธ์การทดสอบ: ความจริงที่น่าตกใจ (The Verdict)



Key Takeaway: แม้แต่โมเดลที่ดีที่สุดยังล้มเหลวเกินครึ่งในการใช้งานจริง ช่องว่างระหว่าง ‘ความสามารถทั่วไป’ และ ‘ความชำนาญ MCP’ ยังกว้างมาก

ประสิทธิภาพแบ่งตามโดเมน (Performance by Domain)



จุดแข็ง (Strengths):
Financial Analysis (67.50%)
& Web Searching.

GPT-5

จุดอ่อน (Weaknesses):
Location Navigation (<35%)
& Repository Management.

การนำทางในพื้นที่จริงและการจัดการ Codebase ที่ซับซ้อน เป็นโจทย์ที่ยากที่สุดสำหรับ AI ในปัจจุบัน

ทำไม Agents ถึงล้มเหลว? (Why Do Agents Fail?)



1. Long-Context Challenge

ยิ่งขั้นตอนการทำงานเยอะ จำนวน Tokens ยิ่งทวีคูณ ทำให้โมเดลลืมข้อมูลหรือสับสน



2. Unknown Tools Challenge


โมเดลขาดความคุ้นเคยกับ Parameters ของเครื่องมือจริง ทำให้เกิดการ 'Hallucinate' วิธีการใช้งาน



3. Enterprise Failure


แม้แต่ Agent ระดับองค์กรอย่าง Cursor ก็ยังทำผลงานได้ไม่ดีไปกว่า Framework มาตรฐานอย่าง ReAct

Proprietary vs. Open Source



- **GLM-4.5** เป็นผู้นำในกลุ่ม Open Source ชนะโมเดลปิดบางตัวเช่น Claude-3.7-Sonnet
- โมเดล Open Source ขนาดใหญ่ (120B+) เริ่มตามทัน แต่ยังต้องการการปรับปรุงเรื่องการใช้เครื่องมือ

ทิศทางอนาคต (Future Directions)




Beyond ReAct



Framework แบบ ReAct เริ่มถึงทางตัน
ต้องมีสถาปัตยกรรม Agent แบบใหม่

Few-Shot Tool Learning



Agents ต้องเรียนรู้วิธีใช้เครื่องมือใหม่ๆ ได้
'หน้างาน' โดยไม่ต้องเทรนใหม่

Better Context Management



ต้องมีการจัดการ Long-context
ที่ดีกว่านี้เพื่อรองรับงานหลายขั้นตอน

บทสรุป (Key Takeaways)



Benchmark แรกของโลก ที่วัดผลด้วย MCP Server จริง ครอบคลุม 6 โดเมน



การประเมินผลที่เข้มงวด ด้วยระบบ Execution-based ไม่ใช่ AI ตัดสิน



ความจริงในปัจจุบัน: โมเดล SOTA (GPT-5) ยังทำสำเร็จเพียง ~44%



Call to Action: เข้าร่วมการพัฒนาและทดสอบได้ที่ GitHub & Website



github.com/SalesforceAIResearch/MCP-Universe



mcp-universe.github.io