

การวัดผลตัวแทน AI: การสำรวจและ แนวโน้มอนาคต

Evaluation of LLM-based Agents:
A Comprehensive Survey

การนำทางสู่ยุคใหม่: จากโมเดลภาษาแบบนิ่ง
สู่ระบบอัตโนมัติที่คิดและทำเองได้



Based on 'Survey on Evaluation of LLM-based Agents' (Yehudai et al., 2025)

บทนำ: การเปลี่ยนผ่านจากผู้รู้ (LLM) สู่ผู้กระทำ (Agent)



Static LLM (ยุคโมเดลภาษา)

- **การโต้ตอบแบบนิ่ง:** จำกัดอยู่ที่การถาม-ตอบ (Single-turn)
- **Stateless:** ไม่มีการจำค่าสถานะระหว่างขั้นตอน
- **Passive:** รอคำสั่ง ไม่มีการกระทำต่อโลกภายนอก




LLM-based Agent (ยุคตัวแทนอัตโนมัติ)

- **Multi-step Flow:** ทำงานเป็นลำดับขั้นเพื่อแก้ปัญหาซับซ้อน
- **Stateful:** รักษาบริบทและความต่อเนื่องของข้อมูล
- **Environment:** ใช้เครื่องมือ (Tools) และตอบสนองต่อสภาพแวดล้อมจริง

Bottom Line: เกณฑ์วัดผลเดิมไม่เพียงพอ เราต้องการมาตรฐานใหม่เพื่อวัดความสามารถในการ 'กระทำ' (Agency)

ภาพรวม: 4 มิติสำคัญของการวัดผล

Overview: The 4 Dimensions of Evaluation



มิตที่ 1: การวางแผนและการให้เหตุผล (Planning & Reasoning)

Agent ต้องแตกปัญหาใหญ่ให้เป็นงานย่อย และบริหารจัดการลำดับขั้น

The What

ความสามารถในการย่อยปัญหา (Decomposition) และการสร้างเส้นทางสู่คำตอบ (Execution path).




The Benchmarks & Insights

- **Reasoning:** GSM8K, MATH, HotpotQA
- **Planning:** PlanBench, AgentBoard, Natural Plan

Critical Insight:

โมเดลปัจจุบันทำได้ดีในการวางแผนระยะสั้น (Tactical) แต่ยังคงมีปัญหากับงานระยะยาวที่ซับซ้อน (Strategic) ซึ่งต้องการการติดตามสถานะ (State tracking) และการแก้ไขข้อผิดพลาด

มิตที่ 1: การใช้เครื่องมือและการสะท้อนคิด (Tool Use & Reflection)



Function Calling (การเรียกใช้ฟังก์ชัน)

จากการเรียก API ง่ายๆ สู่การ
จัดการ Tool ที่ซับซ้อนและมี
ลำดับขั้น (Nested & Stateful).

Benchmarks

- **ToolBench**
- **BFCL** (Berkeley Function Calling Leaderboard)
- **API-Bank**




Self-Reflection (การสะท้อนคิด)

ความสามารถในการตรวจสอบและ
แก้ไขข้อผิดพลาดของตนเอง
(Self-correction) เรียนรู้จาก
Feedback.

Benchmarks

- **LLF-Bench**
- **Reflection-Bench**





มิตที่ 1: หน่วยความจำ (Memory)

กุญแจสำคัญสู่ความต่อเนื่องและการเรียนรู้ระยะยาว

Short-term

หน่วยความจำระยะสั้น

Context Window
(หน้าต่างบริบท)



Long-term


หน่วยความจำระยะยาว

Database/Vector Store
(ฐานข้อมูล / เวกเตอร์สโตร์)

Retrieval (การดึงข้อมูล): การดึงข้อมูลจากเอกสารยาว
(Benchmarks: *ReadAgent*, *MemGPT*)



Episodic Memory (การจำเหตุการณ์ในอดีต): การจำเหตุการณ์ในอดีตเพื่อปรับปรุงการตัดสินใจในอนาคต




StreamBench

วัดความสามารถในการเรียนรู้ต่อเนื่อง
(Continuous improvement) จาก Feedback



MemGPT

จัดการระบบความจำแบบ Tiered memory
system (เสมือน OS)



มิตที่ 2: ตัวแทนสำหรับเว็บและวิศวกรรมซอฟต์แวร์

(Web & Software Agents)



Web Agents (Digital Navigators)

Task: ท่องเว็บ จองตั๋ว
ซื้อป๊อปปิ้ง

Benchmarks

- WebArena
- Mind2Web
- WebLinX



Insight: เปลี่ยนจาก Simulation ง่ายๆ สู่เว็บจริง
ที่มีความซับซ้อนทางสายตา (Visual Web)



Software Agents (The Coders)

Task: เขียนโค้ด แก้บั๊ก
พัฒนาฟีเจอร์

Benchmarks

- SWE-bench (The Gold Standard)
- ใช้ GitHub issues จริง (Real-world repositories)




Insight: ความท้าทายสูงมาก: Success rate
ของโมเดลส่วนใหญ่ยังต่ำกว่า 2%

มิติที่ 2: ตัวแทนด้านวิทยาศาสตร์และการสนทนา

(Scientific & Conversational Agents)



Scientific Agents (Researchers)



Benchmark: **DiscoveryWorld, LAB-Bench, SciCode**

เริ่มมีการวัดผล 'ความคิดสร้างสรรค์' และคุณภาพการ Peer Review



Conversational Agents (Customer Service)

Focus: การทำตามนโยบายองค์กร (Policy Compliance) และการใช้เครื่องมือระหว่างคุย

Benchmark: **τ -Bench** (Retail/Airline policy), **ABCD**

มิตที่ 3: ตัวแทน AI อเนกประสงค์ (Generalist Agents)

ความสามารถในการบูรณาการทักษะเพื่อแก้ปัญหาแบบเปิด



Agents ที่ไม่ได้ฝึกมาเพื่องานเดียว แต่สามารถควบคุมคอมพิวเตอร์ได้เหมือนมนุษย์

GAIA



คำถามที่ดูเหมือนง่ายสำหรับมนุษย์ แต่ยากสำหรับ AI เพราะต้องใช้เหตุผล + เครื่องมือ + การท่องเว็บรวมกัน

OSWorld



การควบคุมระบบปฏิบัติการ (Operating System) เต็มรูปแบบ (Multimodal)

AppWorld & OmniACT



การทำงานข้ามแอปพลิเคชันเพื่อทำงานให้สำเร็จ

มิตที่ 4: ระบบนิเวศสำหรับนักพัฒนา

(The Developer's Ecosystem)



Observability & Evaluation Platforms

เครื่องมือที่ใช้วัดผลระหว่างการพัฒนาและใช้งานจริง (Development & Deployment)



LangSmith



Langfuse




Galileo

Galileo



Google
Vertex AI




Gym-like Environments

สภาพแวดล้อมจำลองสำหรับการฝึกฝน Agent (Simulated Training)

- **BrowserGym**: สำหรับฝึก Web Agents
- **SWE-Gym**: สำหรับฝึก Coding Agents
- **MLGym**: สำหรับฝึก Research Agents

วิธีการวัดผลของเฟรมเวิร์ก

(How Frameworks Measure Success)



Stepwise Evaluation (วัดผลรายขั้นตอน)

ตรวจสอบการกระทำทีละขั้น: Agent เลือกเครื่องมือถูกไหม?
Parameter ถูกต้องหรือไม่?

Trajectory-Based Assessment (วัดผลเส้นทาง)

วิเคราะห์ลำดับการตัดสินใจเทียบกับเส้นทางที่เหมาะสม (Optimal path).
ตรวจสอบว่า Agent วนลูปหรือหลงทางหรือไม่?

Final Response Evaluation (วัดผลลัพธ์สุดท้าย)

คำตอบถูกต้องหรือไม่? (Success/Failure).
มักใช้ LLM-as-a-Judge ในการให้คะแนนคุณภาพ

แนวโน้มปัจจุบัน: ความสมจริงและความท้าทาย

(Current Trends)



Realistic & Challenging (สมจริงและยากขึ้น)

เปลี่ยนจาก Toy problems สู่ Real-world tasks.

Data Point: ใน **SWE-bench** โมเดลส่วนใหญ่ยังทำคะแนนได้ต่ำมาก สะท้อนความยากของงานจริง



Live Benchmarks (เบนช์มาร์กที่มีชีวิต)


ข้อมูลหยุดนิ่ง (Static Data) ล้าสมัยเร็วและเสี่ยงต่อการที่โมเดลจำคำตอบ (Data Contamination).

Solution: การอัปเดตข้อมูลต่อเนื่อง เช่น **BFCL** หรือ **SWE-bench Verified** ที่มีการปรับปรุง Test cases ตลอดเวลา

ช่องว่างและทิศทางในอนาคต

(Emergent Directions & Gaps)

Granularity (ความละเอียด)



Problem: รู้แค่ 'ล้มเหลว'
แต่ไม่รู้ 'ทำไม'

Need: การวินิจฉัยระดับ
Root cause และการวิเคราะห์
รายขั้นตอน


Cost & Efficiency (ต้นทุนและประสิทธิภาพ)



Problem: ความเร่งแลกมา
ด้วยอะไร?

Need: การวัด Token usage,
API costs, และเวลาที่ใช้
(Latency)

Safety & Compliance (ความปลอดภัย)



Problem: ยังถูกทดสอบน้อย
เกินไป

Need: การป้องกัน Bias, การ
โจมตี (Adversarial attacks),
และการปฏิบัติตามกฎองค์กร

บทสรุป: กลยุทธ์การวัดผลแบบรอบด้าน

Summary: A Multidimensional Strategy

ประเมินทั้ง 4 มิติ
(Capabilities, Domain,
Generalization,
Frameworks)



มองให้ลึกกว่า
Success Rate
(Trajectory & Cost)







ใช้ Environment-based Evaluation
และ Continuous Monitoring



นักพัฒนาต้องเปลี่ยนจากการใช้ Static Dataset มาเป็นการทดสอบในสภาพแวดล้อมจริงเพื่อความสำเร็จที่ยั่งยืน

แผนภาพสรุป Benchmark Landscape

Reasoning 	Planning 	Tool Use 	Web/SWE 	Science 
GSM8K	PlanBench	ToolBench	WebArena	DiscoveryWorld
MATH	AgentBoard	BFCL	SWE-bench	SciCode
HotpotQA	Natural Plan	API-Bank	Mind2Web	LAB-Bench
StrategyQA	Science 	NexusRaven	Generalist 	Memory 
	DiscoveryWorld		GAIA	MemGPT
	SciCode		OSWorld	StreamBench
			AgentBench	LLF-Bench

รวม Benchmark สำคัญสำหรับการวัดผล Agent ในปัจจุบัน