



Merge-of-Thought (MoT): การกลั่นกรองความรู้ จากหลากหลายครูผู้สอนสู่โมเดลขนาดเล็ก



เอาชนะ DeepSeek-R1 และ OpenAI-o1 ด้วยข้อมูลเพียง 200 ตัวอย่าง

ความสำคัญของ Long CoT Distillation

- **เป้าหมาย:** ถ่ายโอนความสามารถในการให้เหตุผล (Reasoning) จากโมเดลขนาดใหญ่สู่โมเดลขนาดเล็กที่ใช้งานได้จริง
- **วิธีปัจจุบัน:** มักใช้โมเดล 'Oracle' เพียงตัวเดียว (Single-Teacher) เป็นต้นแบบ



กับดักของการเลือกครูเพียงคนเดียว (The Single Teacher Fallacy)

ข้อมูลยืนยันว่าไม่มี 'ครูที่ดีที่สุด' เพียงคนเดียว

	Dataset 1	Dataset 2	Dataset 3
Student A			
Student B			
Student C			

-  นักเรียนแต่ละคนเรียนรู้ได้ดีจากครูที่ต่างกัน
-  แม้แต่นักเรียนคนเดิมก็อาจต้องการครูคนใหม่เมื่อเปลี่ยนชุดข้อมูล


ทำไมการรวมข้อมูลแบบปกติ (MTD) ถึงไม่ได้ผล

ปัญหาของ Multi-Teacher Distillation (MTD)




Reasoning Path

Chaos Diagram




ความขัดแย้ง: ครูแต่ละคนมี 'สไตล์' และ 'อคติ' (Inductive Bias) ที่ต่างกัน
ผลลัพธ์: การนำข้อมูลมารวมกันเฉยๆ ทำให้เกิดความขัดแย้ง (Supervision Conflicts) และสัญญาณรบกวน (Noise)

นวัตกรรม Merge-of-Thought (MoT)



เฟรมเวิร์กที่ผสานความสามารถในการให้เหตุผลผ่านการ ‘แยกสายเรียนรู้’
และ ‘รวมน้ำหนัก’ ซ้ำๆ เพื่อหาฉันทามติ (Consensus)


ขั้นตอนที่ 1: Branch Training (การแยกสายการเรียนรู้)



- โมเดลนักเรียนถูกแยกออกเป็นหลาย 'สาขา' (Branches)
- แต่ละสาขาเรียนรู้แบบ SFT จากครูคนเดียวโดยเฉพาะ
- เป้าหมาย: เลียนแบบกระบวนการคิดของครูคนนั้นๆ ให้สมบูรณ์

ขั้นตอนที่ 2: Weight Merging (การผสานน้ำหนัก)

Many-to-One



- นำพารามิเตอร์จากทุกสาขามารวมกัน (Average Parameters)
- ผลลัพธ์: สัญญาณรบกวน (Noise) ทางสถิติถูกหักล้าง แต่ตรรกะที่ถูกต้อง (Consensus) ถูกเสริมให้แข็งแกร่งขึ้น

ฉันทามติทางความคิด: กรอง Noise เก็บ Logic


Low Confidence
(Style/Bias)

Therefore, the area is $1+1=2$


High Confidence
(Logic)

MoT ลดความมั่นใจในคำเชื่อมที่เป็นสไตรล์ส่วนตัว
แต่รักษาความแม่นยำในขั้นตอนการคำนวณ

เสถียรภาพของการเรียนรู้: Loss Landscape ที่ราบเรียบกว่า




ความไม่เสถียร (Instability)



ความเสถียร (Stability)


- การผสานน้ำหนักช่วยให้โมเดลอยู่ในจุดที่ Loss Landscape ที่ราบเรียบ (Flatter Region)
- ลดความเสี่ยงจากการจดจำข้อสอบ (Overfitting) และทนทานต่อสัญญาณรบกวน

การตั้งค่าการทดลอง: ข้อมูลน้อย แต่ผลลัพธ์มหาศาล



ข้อมูล: ใช้โจทย์คณิตศาสตร์เพียง ~200 ข้อ
(BOBA-200, S1K-200)
นักเรียน: Qwen3-14B (Small Model)
ครู: QWQ, DeepSeek-R1, Qwen3-32B

ผลลัพธ์: เอาชนะยักษ์ใหญ่ด้วยโมเดลขนาดเล็ก



Qwen3-14B (+MoT) มีคะแนนเหนือกว่า DeepSeek-R1 และ OpenAI-o1 บน Benchmark คณิตศาสตร์


ความสามารถทั่วไป: เก่งคณิตศาสตร์โดยไม่ลืมความรู้เดิม



MoT ช่วยลดปัญหา
Catastrophic Forgetting

เมื่อเทียบกับการฝึกด้วย
ครูคนเดียว

Coding & Science:
คะแนนเพิ่มขึ้น



ความยืดหยุ่น: ไม่ต้องเสียเวลาคัดเลือกครู




Diversity > Uniformity

แม้ครูจะมีสไลด์ที่แตกต่างกันมาก (Distribution Shift)
MoT ก็ยังสามารถดึงจุดเด่นมาใช้ได้

ความหลากหลายของครูสำคัญกว่าความเก่งรายบุคคล

อนาคตของการกลั่นความรู้: Selection-Free Distillation




- เปลี่ยนกระบวนการจาก ‘การตามหาครูเทพ’ -> ‘การผสานพลังจากครูหลายคน’
- Impact: ประหยัดพลังงาน ประหยัดข้อมูล และได้ผลลัพธ์ที่ดีกว่า

บทสรุป: 3 เสาหลักของ MoT




Diverse Teachers

ดีกว่าการพึ่งพาครู
เพียงคนเดียว



Iterative Merging

ดีกว่าการรวมข้อมูล
(Data Mixing)



Consensus Reasoning

กำจัด Noise
เก็บ Logic