



Modular Manifolds: การปฏิวัติการหาค่าเหมาะ ที่สุดด้วยเรขาคณิต

แนวทางใหม่ในการควบคุม Weight Matrices
เพื่อเสถียรภาพของโครงข่ายประสาทเทียม

Modular Manifolds: Rethinking Optimization with Geometry



ปัญหาความไม่สมดุลของ Tensor ในการเทรนขนาดใหญ่




เมื่อเทรนโครงข่ายขนาดใหญ่ เราต้องการให้ Tensors ‘มีสุขภาพดี’ (Healthy) คือไม่ใหญ่หรือเล็กจนเกินไป

Current Standard: เราใช้ Normalization กับ **Activations** (เช่น LayerNorm) และ **Gradients** แต่สิ่งหนึ่งที่ขาดหายไปคือ...

The Missing Piece: การทำ Normalization กับ **Weight Matrices** โดยตรง

การกำหนดข้อจำกัด (Constraints) ให้กับ Weights จะช่วยควบคุม Condition Number ให้พฤติกรรมของโมเดลคาดเดาได้

ภาพจำลองของแมนิโฟลด์: พื้นผิวโค้งและพื้นที่สัมผัส



Manifold

พื้นผิวโค้งที่เมื่อซูมเข้าไปใกล้ๆ
จะดูเหมือนพื้นราบ
(Locally flat)


Tangent Space

พื้นที่ราบเสมือน ณ
จุดจุดหนึ่งบนแมนิโฟลด์

$$w \in \mathbb{R}^d, \|w\|_2 = 1$$

$$a \perp w$$


กลไกการเคลื่อนที่: Step และ Retraction



- 1. Tangent Step:**
หาเจาะงทิศทางที่ดีที่สุด
ใน Tangent Space (พื้นที่ราบ)
- 2. Update:**
ขยับไปตามทิศทางนั้นเป็นระยะทาง
 η (Learning Rate)
- 3. Retract:**
ดึงค่าที่ได้กลับลงมาบนพื้นผิว
แมนิโฟลด์ (Project back)


เรขาคณิตเป็นตัวกำหนดทิศทางที่ดีที่สุด

Euclidean Norm



ทิศทางของ Gradient (ลูกศรชมพู)
อาจไม่ใช่ทิศทางที่เราควรเดินเสมอไป


Non-Euclidean Norm



รูปร่างของ 'Unit Ball' เป็นตัวกำหนดว่า
เราจะเดินไปทางไหนได้ไกลที่สุดเพื่อลด Loss

$$\min_{\mathbf{a}} \mathbf{a}^T \mathbf{g} \text{ subject to } \|\mathbf{a}\| = \eta$$

จากเวกเตอร์สู่เมทริกซ์: การควบคุมการยืดขยาย



ใน Transformer, Weights คือ Matrix (W) ที่แปลง Input Vector (x) เป็น Output ($y = Wx$)


เราต้องการให้ Matrix มีพฤติกรรมที่ 'เป็นกลาง' ไม่ยืด (Stretch) หรือหด ข้อมูลมากเกินไป

เครื่องมือวัดคือ **Singular Value Decomposition (SVD)**

รู้จักกับ Stiefel Manifold

Stiefel Manifold: แมนีโฟลด์ของ Matrix ที่มี Singular Values ทั้งหมดเท่ากับ 1

$$\text{Stiefel}(m, n) := \{W \in \mathbb{R}^{m \times n} \mid W^T W = I_n\}$$



Tangent Space Condition

$$A^T W + W^T A = 0$$

เงื่อนไขนี้คือการขยายแนวคิดจากทรงกลม
มาสู่โลกของเมทริกซ์

Manifold Muon: อัลกอริทึมสำหรับเมตริกซ์

การผสมผสานระหว่างข้อจำกัดทางเรขาคณิต (Stiefel)
และบรรทัดฐานการวัดระยะ (Spectral Norm)

$$\min_A \text{trace}(G^T A) \longleftarrow \text{Minimize Loss Change}$$

Subject to:

$$\|A\|_{\text{spectral}} \leq \eta \longleftarrow \text{Spectral Size Constraint (Muon)}$$

$$A^T W + W^T A = 0 \longleftarrow \text{Tangent Constraint (Stiefel)}$$


การแก้ปัญหาด้วย Dual Ascent

Step 1: Primal (Hard)



Constrained Minimization

Step 2: Saddle Point



Min-Max Lagrange

Step 3: Dual (Solvable)




Unconstrained Maximization
(Gradient Ascent)

$$\max_{\Lambda} - \eta \times \left\| \mathbf{G} + 2\mathbf{W}(\mathbf{\Lambda} + \mathbf{\Lambda}^T) \right\|_{\text{nuclear}}$$



เราเปลี่ยนรูปปัญหาเพื่อให้สามารถใช้ Gradient Ascent
หาค่าตัวแปร Dual ($\mathbf{\Lambda}$) ได้ง่ายขึ้น

ขั้นตอนการทำงานของ Manifold Muon



ผลลัพธ์การทดลอง: ประสิทธิภาพและความเสถียร


CIFAR-10 Training Comparison: Manifold Muon vs. AdamW




Manifold Muon ให้ความแม่นยำสูงกว่า และรักษา Singular Values ให้เป็น 1 ตลอดการเทรน

การขยายสเกลด้วย Modular Manifolds

- เราไม่สามารถมองแต่ละ Layer แยกจากกันได้
- **Budgeting Learning Rates:** เราต้องจัดสรร Learning Rate ตามความไว (Sensitivity) ของแต่ละ Layer
- Modular Manifold คือระบบที่ช่วยคำนวณความไวเหล่านี้โดยอัตโนมัติ



กฎการประกอบร่างโมดูล (Rules of Composition)



The 3 Rules


- **Function:** $f_3 = f_2(f_1(x))$
(Composition)
- **Manifold:** $\mathcal{M}_1 \times \mathcal{M}_2$
(Cartesian Product)
- **Norm:** $\max(s_1 \|w_1\|, s_2 \|w_2\|)$
(Weighted Max)

กฎเหล่านี้ช่วยให้เราสร้าง Optimizer แยกสำหรับแต่ละ Layer ได้อย่างอิสระแต่สอดคล้องกัน

ทิศทางการวิจัยในอนาคต



Attention Heads
ควรรอยู่บน Manifold
แบบไหน?



Low-precision
training & floating
point constraints.



ปรับปรุง Dual Ascent
ให้เร็วกว่านี้



โลกของ Neural
Networks อาจไม่ใช่
Riemannian (Norm
balls มีมุมแหลม)

บทสรุป: ส่วนภาคของการออกแบบ Optimizer

- 1. Constraint is Control:** การจำกัด Weights ให้อยู่บน Manifold ช่วยสร้างเสถียรภาพ
- 2. Geometry is Key:** เรขาคณิตเป็นตัวกำหนดวิธีการอัปเดตที่ดีที่สุด (ไม่ใช่แค่ Gradient)
- 3. Co-Design:** อนาคตคือการออกแบบ Architecture และ Optimizer ไปพร้อมๆ กัน

“We need to keep tensors healthy.”