

ImageNet จบแล้วหรือยัง?

Are we done
with ImageNet?

การประเมินมาตรฐานทองคำใหม่
และก้าวต่อไปของ Computer Vision

สรุปงานวิจัยโดย Google Brain & DeepMind (Beyer et al., 2020)



ทศวรรษแห่ง-ความก้าวหน้า (The Legacy)



Exhibit

มาตรฐาน The Benchmark

ตลอด 10 ปีที่ผ่านมา ILSVRC หรือ 'ImageNet' คือสนามประลองหลักที่ผลักดันให้เกิดนวัตกรรมอย่าง AlexNet และ ResNet

Exhibit

ข้อสมมติฐาน The Assumption

เราเชื่อมาตลอดว่า 'ความแม่นยำ' (Accuracy) ที่สูงขึ้นบน ImageNet แปลว่าโมเดลมีความฉลาดและความเข้าใจภาพทั่วไป (Generalization) มากขึ้น

Exhibit

สถานะปัจจุบัน Status Quo

โมเดลยุคใหม่ทำคะแนนได้สูงขึ้นเรื่อยๆ จนดูเหมือนว่าเรากำลังจะแก้โจทย์นี้ได้สมบูรณ์แล้ว




EXHIBIT B: OVERFITTING TO THE LABEL

สัญญาณเตือน: เรากำลังเดินหลงทาง? (The Suspicion)

งานวิจัยตั้งคำถามสำคัญ: ความแม่นยำที่เพิ่มขึ้นในช่วงหลัง เกิดจากการที่ AI เข้าใจภาพดีขึ้นจริง หรือแค่เรียนรู้ที่จะ ‘Overfit’ กับข้อบกพร่องของคนแปะป้าย (Labeling procedure)?

The Hypothesis: เมื่อโมเดลเริ่มเก่งมากๆ คะแนนที่เพิ่มขึ้นอาจไม่ได้สะท้อนความสามารถในการมองเห็น (Perception) แต่สะท้อนความสามารถในการเดาใจคนเฉลยข้อสอบ

รอยร้าวที่ 1: หนึ่งภาพไม่ได้มีแค่หนึ่งคำตอบ (Single Label Limit)




EXHIBIT A: SINGLE LABEL LIMIT

The Problem

ImageNet บังคับให้หนึ่งภาพมี ‘คำตอบที่ถูก’ เพียงข้อเดียว (Single label annotation)

The Flaw

ถ้าโมเดลตอบว่า ‘ค้อน’ แต่เฉลยในระบบคือ ‘สว่าน’ โมเดลจะถูกตัดสินว่า **ผิดทันที** ทั้งที่มันโฟกัสมองเห็นถูกต้อง สิ่งนี้ทำให้การวัดผลคลาดเคลื่อนจากความเป็นจริง

รอยร้าวที่ 2: ความกำกวมและกับดักภาษา (Ambiguity & Noise)



EXHIBIT A: AMBIGUITY OF OBJECTS

ImageNet Label: Quill (ปากกาขนนก) ❌

Reality: Feather boa (ผ้าพันคอขนสัตว์) ✅



EXHIBIT B: LINGUISTIC TRAPS


Ambiguity: Laptop vs. Notebook

คอมพิวเตอร์พกพาเหมือนกัน
แต่มนุษย์แยกความต่างไม่ได้ชัดเจน

เมื่อข้อสอบมีความกำกวม โมเดลที่ทำคะแนนได้สูงคือโมเดลที่จำเก่ง ไม่ใช่โมเดลที่เข้าใจเก่ง

สร้างไม้บรรทัดอันใหม่: Real Labels

ทีมวิจัยสร้างชุดเจลาใหม่สำหรับ Validation Set ชื่อว่า Real (Reassessed Labels)



Step 1: Proposals

ให้โมเดล 19 ตัวช่วยกันเสนอ
คำตอบที่เป็นไปได้



Step 2: Human Verification

ให้มนุษย์ (Raters) ตรวจสอบว่า
คำตอบไหน 'ใช่' บ้าง (Multi-label)



Step 3: Quality Control

ใช้สถิติกรองความผิดพลาดและ
ใช้ Expert ในหมวดสัตว์ต่างๆ

เปรียบเทียบมาตรฐาน: ImageNet vs. ReaL

Original ImageNet Labels	ReaL (Reassessed Labels)
- มีคำตอบถูกเพียง 1 ข้อ (One-hot) - มี Noise และความกำกวมสูง - ตัดสินโมเดลว่าผิด หากตอบไม่ตรงกับเฉลยใบเดียว	- รองรับหลายคำตอบ (Multi-label) - ผ่านการกรองโดย Expert และโมเดลหลายตัว - วัดผลที่ความแม่นยำจริง: 'ถ้าโมเดลตอบสิ่งที่อยู่ในภาพได้ ถือว่าถูก'



For each of the 4 labels, select whether it appears in the image, then .



laptop, clag, dender	mailbag, pordag	porro	wofol, lthbAl, outtroo, prolatbook
☐ Yes. Clag was first in the image ☒ No. It was second in the image	☐ Yes. Pordag was first in the image ☐ No. It was second in the image	☐ Yes. Porro was first in the image ☒ No. It was second in the image	☒ Yes. Wofol was first in the image ☐ No. It was second in the image
			

EXHIBIT D: MULTI-LABEL CONCEPT (ReaL INTERFACE)


ความจริงที่ปรากฏ: กราฟที่แยกออกจากกัน (The Divergence)



Insight: โมเดลยุคใหม่
คอนเนตติ้งกับ คะแนน
ImageNet สูงขึ้น แต่
ความถูกต้องจริง
(Real) เริ่มไม่เพิ่มตาม
→ **Overfitting**

EXHIBIT E: MODEL ACCURACY DIVERGENCE (SCATTER PLOT)

เมื่อ AI แม่นกว่าคนเฉลยข้อสอบ




จากการประเมินด้วยมาตรฐานใหม่ (ReaL) พบเรื่องน่าตกใจ:

- โมเดลชั้นนำอย่าง Noisy Student และ BiT-L ทำนายสิ่งที่อยู่ในภาพได้ตรงใจมนุษย์มากกว่าป้ายกำกับเดิมเสียอีก


ฉลาก ImageNet เดิม ไม่ใช่ตัวแทนความถูกต้องอีกต่อไป

กับดักความสัมพันธ์ (Co-occurrence Bias)





- โมเดลเรียนรู้ที่จะ ‘เดา’ จากบริบทมากกว่าการมองเห็นวัตถุนั้นจริงๆ
- ตัวอย่าง: ใน ImageNet รูป ‘Desktop Computer’ มักมาคู่กับ ‘Monitor’ (87%)
- Result: โมเดลทายถูกถึง 71.1% เพราะมันจำ Pattern ว่าถ้าเห็นจอคอมฯ ให้ทายว่า Desktop ไว้ก่อน แม้ในภาพนั้น Desktop อาจจะถูกบังอยู่ก็ตาม

ทางออกที่ 1: เลิกบังคับเลือกด้วย Sigmoid Loss




บังคับเลือก 1 คำตอบ
(Winner takes all)



อิสระต่อกัน
(Independent Binary Classification)

อนุญาตให้โมเดลทำนายหลายวัตถุพร้อมกันได้
ลดการลงโทษเมื่อตอบถูกแต่ไม่ตรงเฉลยใบเดียว

ทางออกที่ 2: ล้างข้อมูลให้สะอาด (Clean Training Data)



- Garbage In, Garbage Out: การลบข้อมูลที่ผิดพลาดช่วยให้โมเดลเรียนรู้ได้ดีขึ้น โดยเฉพาะเมื่อเทรนนานๆ

ผลลัพธ์: เก่งขึ้นจริง ไม่ใช่แค่คะแนนเพื่อ

EXHIBIT J: RESNET-50 (900 EPOCHS) RESULTS

78.5% Accuracy

with Sigmoid + Clean Data

vs 76.0% Baseline

- No Overfitting:
ยิ่งเทรนนาน ยิ่งเก่งขึ้น
แม้จะผ่านไป 900
epochs
- Real Score
Improvement:
ความถูกต้องบน
มาตรฐานใหม่เพิ่มขึ้น
+1.6%

บทสรุป: มาตรฐานใหม่แห่งยุคถัดไป

EXHIBIT 1:



The Limit

โมเดล AI ฉลาดเกินกว่าที่ ImageNet ฉบับดั้งเดิมจะวัดผลได้เที่ยงตรงแล้ว

EXHIBIT 2:



The Reality

Real Labels ให้ภาพความเป็นจริงได้ดีกว่า Accuracy แบบเดิม

EXHIBIT 3:



The Solution

ใช้ Sigmoid Loss และ Clean Data เพื่อปลดล็อกศักยภาพที่แท้จริง

ก้าวต่อไปของ Computer Vision (Future Outlook)



**ImageNet ยังไม่ตาย
แต่เราต้องใช้มันอย่างระมัดระวัง**

**ถึงเวลาที่นักพัฒนาจะเลิกไล่ล่าตัวเลขบนกระดาษ
และหันมาสร้างโมเดลที่เข้าใจความซับซ้อนของโลกความ
จริง (Real World) อย่างแท้จริง**