

OPENCUA: เปิดประตูสู่ยุคใหม่ของ Computer-Use Agents

เฟรมเวิร์กแบบ Open-Source ที่ครอบคลุม
ตั้งแต่การเก็บข้อมูลไปจนถึงโมเดลระดับ SOTA

นำเสนอระบบนิเวศแรกที่เปิดกว้างอย่างแท้จริงสำหรับการ
สร้าง Agent ที่สามารถควบคุมคอมพิวเตอร์ได้เหมือนมนุษย์
ครอบคลุมทั้ง Infrastructure, Dataset, Training Recipe
และ Benchmark


XLANG Lab, The University of Hong Kong & Partners



จาก ‘การมองเห็น’ สู่ ‘การลงมือทำ’: กำเนิด Computer-Use Agents (CUAs)

วิวัฒนาการของ Vision-Language Models (VLMs) ที่ไม่ได้จำกัดอยู่แค่การแชทหรือวิเคราะห์ภาพ แต่สามารถควบคุม Mouse และ Keyboard เพื่อทำงานแทนมนุษย์

Professional Work: เขียนโค้ดใน
VSCode, จัดการไฟล์ข้าม OS



Daily Tasks: จองตั๋วเครื่องบิน,
สั่งซื้อสินค้า, จัดการปฏิทิน



ปัญหา ‘ประตูที่ปิดตาย’ (The Closed Door Problem)



Proprietary Models
(e.g., Claude 3.5 Sonnet)

ประสิทธิภาพสูง
แต่ ‘สูตรลับ’
และข้อมูลถูกปิดเป็น
ความลับทางการค้า


**Open Source
Community**




- ❌ **Scalable Infrastructure:** ไม่มีเครื่องมือเก็บข้อมูลที่รองรับหลาย OS
- ❌ **High-Quality Data:** ขาด Dataset ขนาดใหญ่ที่มีความหลากหลาย
- ❌ **Training Recipes:** ไม่รู้วิธีการฝึกสอน การวางแผนที่ซับซ้อน

OPENCUA Framework: โซลูชันแบบครบวงจร

การเปลี่ยนกระบวนการทัศน์จากการพึ่งพาโมเดลปิด สู่รากฐานที่เปิดกว้างสำหรับทุกคน



AgentNet Tool: โครงสร้างพื้นฐานสำหรับการเก็บข้อมูล



Action Reduction

ระบบอัตโนมัติที่ย่อการขยับเมาส์นับพันครั้งให้เหลือเพียง 'Meaningful Actions' (เช่น click, drag, type) เพื่อให้โมเดลเรียนรู้ได้ง่าย

Task Instruction
(คำสั่งงาน)

Action Stream
(บันทึก Video +
Mouse/Keyboard)

Cross-OS Support
(Windows, macOS, Ubuntu)

AgentNet Dataset: คลังข้อมูลขนาดใหญ่และหลากหลายที่สุด


22,625 Trajectories

ใหญ่ที่สุดสำหรับ Desktop

3 Operating Systems


Windows, macOS, Ubuntu

140+ Apps / 190+ Websites



ทำไมแค่ ‘ข้อมูล’ ถึงยังไม่เพียงพอ?

(The Failure)



Base Recipe:
Success Rate < 5%
(โมเดลขาดความเข้าใจบริบท)

(The Insight)




The Missing Link: Agent ที่ัวไปเห็นแค่ฟลักเซล แต่ขาดเสียงในใจ (Inner Monologue)




Solution: Reflective Long Chain-of-Thought (CoT)

Reflective Long CoT: สร้างสมองให้ Agent คิดก่อนทำ




Model mistakenly clicked...
Reflection: "I need to fix this
by selecting the correct row"

Data Synthesis Pipeline: เปลี่ยนการกระทำเป็น ‘ความคิด’



The Training Recipe: ส่วนผสมที่ลงตัว



Context Encoding: การจดจำอดีตเพื่อวางแผนอนาคต

Visual History (3 Frames)




Textual History


Action 1: click(File)... Action 2: click(Save)...

บันทึกเฉพาะ L1 Action เพื่อประหยัด Token และรองรับ Long-horizon tasks

ผลลัพธ์ที่เหนือกว่า: SOTA บน OSWorld-Verified



Generalization & Grounding: เข้าใจ UI อย่างแท้จริง



Grounding Ability

60.8%


ScreenSpot-Pro Accuracy

37.3%

UI-Vision Accuracy

โมเดลเข้าใจองค์ประกอบ GUI ข้ามระบบปฏิบัติการ
(Windows / macOS / Ubuntu) ไม่ใช่แค่การจดจำตำแหน่ง

Scaling Laws: ยิ่งขยาย ยิ่งเก่ง



Inference Scaling

- More Steps = Better Results (15 -> 100 steps)
- Pass@N (Multiple Attempts): Success Rate increases to 53.2%
- Conclusion: ยังมีพื้นที่ให้พัฒนาต่อได้อีกมาก (Huge headroom)

อนาคตที่เปิดกว้างเริ่มต้นที่นี่ (The Future is Open)

ร่วมเป็นส่วนหนึ่งของการพัฒนาและใช้งาน OPENCUA



AgentNet Tool



22.6K Dataset



Models (7B - 72B)



<https://opencua.xlang.ai>

XLANG Lab