




PaperDebugger: ระบบ Multi-Agent แบบ Plugin สำหรับการเขียนงานวิชาการใน Editor

ยกระดับการเขียนวิจัยด้วย AI ที่ผสานรวมกับ Overleaf อย่างสมบูรณ์


Junyi Hou, Andre Lin Huikai, Nuo Chen, Yiwei Gong, Bingsheng He
National University of Singapore & Independent Researchers

เผยแพร่ใน: WWW Companion '26

ทำไมต้องออกจาก Editor เพื่อขอความช่วยเหลือ?

กระบวนการทำงานแบบเดิมสร้าง 'แรงเสียดทาน' ให้กับการเขียน

Workflow ปัจจุบัน (Current Workflow)




- ประวัติการแก้ไขกระจัดกระจาย
- สูญเสียความเป็นเหตุเป็นผล
- ขัดจังหวะความคิด

Ideal Workflow



เครื่องมือภายนอกอย่าง Writeful11 ทำได้เพียงแค่แนะนำไวยากรณ์ผิวเผิน
แต่ไม่เข้าใจโครงสร้างของงานวิจัย

การผสานรวม Native Intelligence เข้าสู่ Overleaf



∞ ไร้รอยต่อ (Seamless)

ไม่ต้อง Copy-Paste อีกต่อไป
ทำงานบนข้อความที่เลือกได้ทันที


📁 ตระหนักบริบท (Context-Aware)

เข้าใจโครงสร้าง LaTeX
และประวัติการแก้ไข

📄 แก้ปัญหาได้จริง (Deterministic Patches)

ส่งกลับเป็น Patch ที่แม่นยำ
ไม่ใช่แค่ข้อความแทรก

Workflow การตรวจสอบและแก้ไขแบบ 'Diff-Based'



จาก Hallucination สู่การตรวจสอบด้วยข้อมูลจริง



Deep Research

ค้นหาคitations ที่เกี่ยวข้องจาก arXiv และฐานข้อมูลจริง



Fact-Checking

ลดการมั่วข้อมูล (Hallucination) ด้วยการอ้างอิงแหล่งที่มาที่ตรวจสอบได้



Relevance Scoring

จัดอันดับความเกี่ยวข้องของบทความด้วย LLM

Deep Research Insights

1. Finetune-RAG: Fine-Tuning Language Models to Resist Hallucination in Retrieval-Augmented Generation

Authors: Zhan Peng Lee, Andre Lin, Calvin Tan

Published: 2025-05-20

Source: arXiv:2505.10792

Relevance Score: 0.9127


Why This Paper Matters:

This paper targets the exact problem in your draft: training LLMs to resist hallucinating when RAG retrieval includes misleading content. It contributes a purpose-built dataset that mimics real-world retrieval imperfections and evaluates with an LLM-as-judge pipeline (Bench-RAG using GPT-4o) for accuracy, relevance, helpfulness, and depth.

Key Technique:


Supervised fine-tuning with mixed-context RAG inputs (one factual, one fictitious chunk per question), with both unstructured and XML-structured prompts, evaluated with Bench-RAG (LLM-as-judge).

สถาปัตยกรรมระบบ: สร้างเพื่อรองรับ Scale



Developed with over 24,000 lines of code for stability and efficiency.

การทำงานร่วมกันของ Multi-Agent



XtraMCP: โพรโทคอลเพื่อความถูกต้องของข้อมูล

- พัฒนาต่อยอดจาก Model Context Protocol (MCP) เพื่อรับงานวิชาการโดยเฉพาะ
- ใช้ **Pydantic Schemas** ควบคุมโครงสร้างข้อมูล Input/Output อย่างเคร่งครัด
- ผสานรวม **XtraGPT Model Suite** ที่ปรับจูนมาเพื่อภาษาเขียนเชิงวิชาการ

```
class AcademicPaper(BaseModel):  
    title: str  
    abstract: str  
    citations: List[Citation]  
    # Enforced Schema
```



**Data Integrity
Validated**

การยอมรับและการใช้งานจริง

ยอดติดตั้ง (Installs)



4,116

ผู้ใช้งานที่ลงทะเบียน (Registered Users)



2,761

เรดการเขียน (Writing Threads)



7,447

คะแนนรีวิว (Store Rating)



4.82 / 5

ผู้ใช้ไม่ได้แค่ทดลอง แต่ใช้งานต่อเนื่องหลาย Session

พฤติกรรมการใช้งาน: การวนลูปเพื่อความสมบูรณ์

Top User Actions

ดูความเปลี่ยนแปลง (Diff Viewed)

4,593

คัดลอกคำแนะนำ (Copy Suggestion)

3,214

ใช้งาน Patch (Insert Patch)

2,697

Insight:

นักวิจัยนิยมการปรับแก้แบบซ้ำๆ (**Iterative Refinement**) มากกว่าการให้ AI เขียนให้ทีเดียวจบ และให้ความสำคัญกับการตรวจสอบ Diff ก่อนตัดสินใจ

Case Study: การวิเคราะห์เปรียบเทียบงานวิจัย

การสร้างตารางเปรียบเทียบระเบียบวิธีวิจัย, ชุดข้อมูล, และข้อจำกัดโดยอัตโนมัติ

Key Similarities and Differences			
Aspect	Your Paper (Finetune-RAG)	SFT/Generator Mitigation (AutoRAG-Lo, RA)	Detection/Evaluation (Osiris, Real-Time Benchmarking/Eval Dataset (FaithEval, Bfan, MALTO))
Goal	Reduce hallucination by training LLMs to ignore spurious information at generation time	SFT/Generator Mitigation (AutoRAG-LI to ignore spurious information at generation time is JetBrains Rono	Detection/Evaluation (Osiris, Real-Time Benchmarking/Eval Dataset JetBrains Rono
Dataset	Mixed: factual + plausible fictitious chunk per query	Mixed: factual + plausible fictitious chunk per query cooernion	Detection/Evaluation (Osiris, Real-Time Benchmarking/Eval Dataset (FaithEval). JetBrains Rono
Methodology	SFT of generator on noisy context	SFT of generator on noisy context - SFT of generator on noisy context	SFT of generator on noisy context - SFT of generator on context (FaithEval). JetBrains Rono
Evaluation	LLM-as-Judge (GPT-4o) on factuality, helpfulness, etc.	LLM-as-Judge (GPT-4o) on factuality, helpfulness, etc.	LLM-as-Judge (GPT-4o) on factuality, helpfulness, etc.
Key Difference	Differs from judge-generator; does not use detection at runtime	Differs from judge-generator; does not use detection at runtime, nowver nonionqmmment. JetBrains Rono	Differs from judge-generator; does not use detection at runtime
Limitation	Binary context, does not address multi-distractor or real-time streaming	Binary context, does not address multi-distractor or real-time streaming	Binary context, does not address Real-Time Benchmarking/Eval Dataset JetBrains Rono

Summary Table

	Mitigation (Generator)	Detection/Verifier	Benchmark Uses	Synthetic Negatives	LLM-as-Judge	SFT on Generator	SFT on Detector	Reference-Free	Multi-lingual
Finetune-RAG (yours)	✓	✓	✓		✓	✓	(internal (adaptive)		
AutoRAG-LoRA	✓	✓		(adaptive)	✓	✓	(internal)		
Osiris		✓	(adaptive)				✓		
Real-Time Eval	✓	✓	✓		✓	✓	✓		
FalthEval			✓		✓				
Bfan			✓		(internal)		✓		
MALTO	✓		✓	(internal)					

Takeaways for Positioning Your Work

- Your approach (Finetune-RAG) is most similar to AutoRAG-LoRA in using SFT to mitigate hallucination, but differs by not employing adsptive (detector-triggered) SFT or LoRA.
- Relative to detection-focused works (Dsiris, Bfan, MALTO), your paper aims to reduce hallucination at generation time rather than only catch it post-hoc.
- Unlike FaithEval or Bfan, your focus is not on benchmarking but on intervention; however, using those benchmarks could strengthen your evaluation.

Scenario

ผู้ใช้งานต้องการเปรียบเทียบงานของตนเองกับเปเปอร์อื่นในหัวข้อ Hallucination

Outcome

PaperDebugger สร้างตารางเปรียบเทียบพร้อมสำหรับการอ้างอิงทันที

บทสรุปคุณค่าของ PaperDebugger

Editor-Native



ผสานรวมกับ Overleaf
โดยตรง ลบภาพจำของการ
Copy-Paste

Scalable Architecture



สถาปัตยกรรม
Kubernetes-Native
ที่รองรับการทำงานแบบขนาน

Proven Usability



ได้รับการพิสูจน์แล้วจากผู้
ใช้งานจริงกว่า 2,700 คน

อนาคตของการเขียนงานวิชาการเริ่มที่นี่

Install Extension



****Roadmap****

- รองรับเอกสารขนาดยาว (Long-context support)
- เพิ่ม Agent เฉพาะทาง สำหรับสาขาวิชาต่างๆ

ดาวน์โหลดได้แล้วที่
Chrome Web Store ↓

<https://github.com/PaperDebugger/PaperDebugger>