


สร้าง LLM ที่เรียนรู้จาก Raw Bytes โดยตรง พร้อมการจัดสรรทรัพยากร
การประมวลผลแบบพลวัต (Dynamic Compute Allocation)

สร้าง LLM ที่เรียนรู้จาก Raw Bytes โดยตรง พร้อมการจัดสรรทรัพยากร
การประมวลผลแบบพลวัต (Dynamic Compute Allocation)



คอขวดของ Tokenization: ปัญหาของ "Static Compute"

The Fixed Lens

BPE Tokenizer

Thhe quick brwn fox



Fixed Lens (มุมมองที่ตายตัว):

Tokenization คือการประมวลผลล่วงหน้าแบบ Heuristic ไม่ใช้การเรียนรู้ที่แท้จริง ทำให้โมเดลมีอคติ



Brittleness (ความเปราะบาง):

อ่อนไหวต่อสัญญาณรบกวน (Noise) และคำผิด (Typos)



Inequity (ความไม่เท่าเทียม):

ประสิทธิภาพลดลงในภาษาที่ 'Out of Vocabulary' หรือภาษาที่มีทรัพยากรน้อย



Wasted Compute:


ใช้พลังในการประมวลผลเท่ากันสำหรับคำง่ายๆ (เช่น 'the') และคำยากๆ

การเปลี่ยนผ่านสู่ยุคใหม่: จาก Static Tokens สู่ Dynamic Patches

Old Paradigm: Fixed Compute (BPE)



New Paradigm: Dynamic Compute (BLT)




BLT Concept:

โมเดลจะตัดสินใจเองว่าจะจัดกลุ่มข้อมูล
อย่างไรตามความซับซ้อนของเนื้อหา

Benefit:


‘Compute where it counts’
(ประมวลผลเน้นหนักเฉพาะจุดที่สำคัญ)

กลไกหลัก: การสร้าง Patch ด้วยค่า Entropy



- **Entropy ($H(x_i)$):** มาตรวัดความ ‘ประหลาดใจ’ ของข้อมูลถัดไป
- **Mechanism:** เมื่อโมเดลเจอสิ่งที่คาดเดายาก (Entropy สูง) มันจะสร้าง Patch ใหม่ทันที เพื่อจัดสรรทรัพยากรมาวิเคราะห์จุดนั้น


สถาปัตยกรรม 'The Sandwich Model'



‘สมอง’ หลักที่ประมวลผล Patches
(ทำงานหนักที่สุด แต่รับจำนวนครั้งน้อยกว่า)

Insight: โมเดล Global Transformer ขนาดใหญ่ไม่ต้องรับทุก Byte
แต่รับเฉพาะระดับ Patch ทำให้ประหยัดพลังงานมหาศาล

Zoom In: Local Encoder (จาก Bytes สู่ Meaning)



- **No Vocabulary:**
ไม่มีการเก็บคลังคำศัพท์ตายตัว
- **Hash N-gram Embeddings:**
เทคนิคการจับบริบทระยะใกล้ (เช่น 'ing', 'the') โดยไม่ต้องใช้ Tokenizer
- **Result:**
สร้าง Representation ที่แข็งแกร่ง
และยืดหยุ่นกว่า Token

ประสิทธิภาพ: ทำได้มากกว่า ในทรัพยากรที่น้อยกว่า


Inference FLOPs



เนื่องจาก BLT สร้าง Patch ขนาดยาวสำหรับข้อความที่ง่าย (Predictable) ทำให้ลดจำนวนครั้งที่ Global Transformer ต้องทำงาน

Key Takeaway: การประหยัดทรัพยากรนี้ทำให้เราสามารถขยายขนาดโมเดลให้ใหญ่ขึ้น หรือทำงานได้เร็วขึ้นในงบประมาณเดิม

กฎการขยายขนาด (Scaling Laws): เมื่อ Patch ชนะ Token



- **BLT** ให้ประสิทธิภาพเทียบเท่า Llama 3 ที่ระดับ 8B parameters
- **New Scaling Axis:** เราสามารถเพิ่มขนาด Patch (Patch Size) เพื่อลดต้นทุนโดยไม่เสียประสิทธิภาพ ซึ่งเป็นสิ่งที่ Token-based models ทำไม่ได้


ความทนทาน (Robustness): จุดแข็งของระดับ Byte

Stress Test

Test Type	Input Example	Performance Impact
Normal	The capital of France is Paris.	Llama 3: High  BLT: High 
UPPERCASE Noise	THE CAPITAL OF FRANCE IS PARIS.	Llama 3: Crash (Low Accuracy)  BLT: Stable 
Random Chars	T.h.e c.a.p.i.t.a.l o.f...	Llama 3: Crash  BLT: Stable 
Typos	The capitel of Franse is...	Llama 3: Confused  BLT: Robust 

 **BLT ทำคะแนนนำ Llama 3 ถึง 8 จุดในแบบทดสอบที่มี Noise**

ความเข้าใจระดับ Sub-Word (ผลลัพธ์จาก CUTE Benchmark)



Tokenizers จำคำเป็นก้อนๆ แต่ BLT เข้าใจการสะกดคำ

Result: ชนะขาดลอยในงานด้าน Orthography และ Character Manipulation

ไร้กำแพงภาษา: รองรับ Multilingual และ Long-Tail Data



✓ **Generalization:** BLT ทำงานได้ดีกว่าในภาษาที่ Tokenizer ไม่ได้ถูกปรับจนมาโดยเฉพาะ (เช่น ภาษาไทย)

“Byte-ifying”: การอัปเดต Llama 3 ให้เป็น BLT


Llama 3 Weights



Transfer
Learning

การเรียนรู้แบบถ่ายโอน

BLT Global Transformer



***Performance
Boost***
ประสิทธิภาพเพิ่มขึ้น

เราไม่จำเป็นต้องเทรนใหม่จากศูนย์ (Scratch) เสมอไป
การนำ Weight ของ Llama 3 มาใช้ใน BLT ช่วยเร่งความเร็วในการเทรนและเพิ่มประสิทธิภาพได้ทันที

ตัวอย่างการใช้งานจริง: MMLU Reasoning

The following are multiple choice questions (with answers) about college physics.

Single Patch / 1 Compute Step

A refracting telescope consists of two converging lenses separated by 100 cm. The eyepiece lens has a focal length of 20 cm. The angular magnification of the telescope is

- A. 4
- B. 5
- D. 20

Answer: A

Many Patches / High Compute

...
The muon decays with a characteristic lifetime of about 10^{-6} second into an electron, a muon neutrino, and an electron anti neutrino. The muon is forbidden from decaying into an electron and just a single neutrino by the law of conservation of

- A. charge
- B. mass
- C. energy and momentum
- D. lepton number

Answer: D

The quantum efficiency of a photon detector is 0.1. If 100 photons are sent into the detector, one after the other, the detector will detect photons

- A. an average of 10 times, with an rms deviation of about 4
- B. an average of 10 times, with an rms deviation of about 3
- C. an average of 10 times, with an rms deviation of about 1
- D. an average of 10 times, with an rms deviation of about 0.1

Answer: A


Smart Skipping: โมเดลเรียนรู้ที่จะ 'อ่านข้าม' ส่วนที่ซ้ำซ้อน
ในคำถามปรนัยโดยอัตโนมัติ ทำให้ประหยัดพลังงานสูงสุด

บทสรุป: ทำไม BLT ถึงคืออนาคต



Efficiency

ลด Inference
FLOPs ลง 50%



Performance

ประสิทธิภาพเทียบเท่า
Llama 3 ที่ระดับ
Scale เดียวกัน



Robustness

ทนทานต่อ Noise
และเข้าใจโครงสร้างคำ
(Spelling)



Simplicity

ตัดความซับซ้อนของการ
จัดการ Vocabulary
ทิ้งไป

BLT ไม่ใช่แค่ทางเลือก แต่คือวิวัฒนาการถัดไปของสถาปัตยกรรม LLM

อนาคตที่ไร้ Token (Token-Free Future)

ยุคสมัยของ Tokenizer กำลังจะสิ้นสุดลง ยุคของ Byte เริ่มต้นขึ้นแล้ว

Code & Paper: <https://github.com/facebookresearch/blt>

Based on 'Byte Latent Transformer: Patches Scale Better Than Tokens' (2024).