


Post-Training of Large Language Models (PoLMs): บทสรุปและการสำรวจเชิงลึก

จากการฝึกฝนขั้นต้นสู่การใช้เหตุผลขั้นสูง
การปรับให้สอดคล้องกับมนุษย์ และประสิทธิภาพที่เหนือกว่า



เจาะลึกวิวัฒนาการของ AI จาก ChatGPT สู่ DeepSeek-R1

ปัญหาของ 'ความฉลาดขั้นพื้นฐาน' (The 'Raw Intelligence' Problem)

Pre-training (การฝึกฝนล่วงหน้า)



เปรียบเสมือนสารานุกรมที่มีความรู้มหาศาล
แต่ขาดความเข้าใจในเจตนาของผู้ใช้

- ✗ ความรู้ทั่วไปสูง (General Knowledge)
- ✗ การใช้เหตุผลจำกัด (Restricted Reasoning)
- ⚠ ความไม่แน่นอนทางจริยธรรม (Ethical Uncertainties)


Post-training (การฝึกฝนภายหลัง)



กระบวนการขัดเกลาให้โมเดลมีความเชี่ยวชาญ
ปลอดภัย และใช้งานได้จริง

- ✓ ความแม่นยำเฉพาะงาน (Task Specificity)
- ✓ สอดคล้องกับเจตนาของมนุษย์ (Human Alignment)
- ✓ การให้เหตุผลเชิงตรรกะ (Logical Inference)

แผนภาพภูมิทัศน์ของ PoLMs (The Landscape of PoLMs)



Pillar 1: Fine-Tuning — การสร้างทักษะเฉพาะด้าน (The Skill Builder)



The Concept

Supervised Fine-Tuning (SFT)

การสอนโมเดลให้ปฏิบัติตามคำสั่งโดยใช้ชุดข้อมูลที่มีฉลากกำกับ (Labeled Data) เพื่อเพิ่มความแม่นยำในงานเฉพาะทาง


Instruction Tuning

เทคนิคการปรับแต่งแบบ Adaptive เพื่อให้โมเดลเข้าใจรูปแบบคำสั่งที่หลากหลาย

The Comparison


Full-Parameter Fine-Tuning

ปรับพารามิเตอร์ทั้งหมด
(ใช้ทรัพยากรสูง)



Parameter-Efficient Fine-Tuning (PEFT)

ปรับเฉพาะส่วนที่จำเป็น
(ประหยัดทรัพยากร)



Pillar 2: Alignment — เกราะป้องกันความปลอดภัย (The Safety Guard)



“ความฉลาดเพียงอย่างเดียวไม่เพียงพอ
โมเดลต้องสอดคล้องกับค่านิยมของมนุษย์
(Helpful, Honest, Harmless)”

กลไกการทำงาน (Mechanism)

RLHF (Reinforcement Learning with Human Feedback)
การใช้ผลป้อนกลับจากมนุษย์เพื่อชี้นำพฤติกรรมของโมเดล




วิวัฒนาการของการปรับแต่ง: จาก RLHF สู่ DPO

RLHF (Traditional)	DPO (Direct Preference Optimization)
 The diagram illustrates the RLHF (Traditional) process. It starts with a Model (represented by a brain icon) generating a Response (document icon). This response is evaluated by Human Rank (represented by a person with speech bubbles). The human rank is then used for Reward Model Training (represented by a trophy icon). Finally, the Reward Model Training output is used for PPO (Proximal Policy Optimization) (represented by a bar chart and gear icon) to produce the Final Model (green brain icon).	 The diagram illustrates the DPO (Direct Preference Optimization) process. It starts with Preference Data (represented by a document icon) being processed through a DPO Loss (represented by a gear and balance scale icon) to produce the Final Model (green brain icon). A gold medal icon with the text "The New Standard" is shown above the process.
• ซับซ้อน: ต้องสร้าง Reward Model แยกต่างหาก • ไม่เสถียร: การฝึกด้วย PPO (Proximal Policy Optimization) มีความอ่อนไหว	• Advantage: ตัดขั้นตอน Reward Model ออกไป ทำให้การฝึกเสถียรและรวดเร็วขึ้น • ปรับแต่งโมเดลโดยตรงจากข้อมูลความชอบ (Preference Data)

Pillar 3: Reasoning — จากการจัดจำรูปแบบ สู่การคิดเชิงตรรกะ (**System 2 Thinking**)

โมเดลยุคใหม่ไม่ได้แค่ ‘ตอบทันที’ (System 1)
แต่เรียนรู้ที่จะ ‘คิดใคร่ครวญ’ (System 2) ก่อนให้คำตอบ



1. Chain-of-Thought (CoT)


การแตกปัญหาซับซ้อนออกเป็นขั้นตอนย่อย



2. Self-Refinement

โมเดลตรวจสอบและแก้ไขคำตอบของตัวเอง
(Iterative feedback)


กลไกการสร้างเหตุผล: DeepSeek-R1 และ OpenAI o1




****Core Concept: "Cold Start" RL****

- การค้นพบรูปแบบการคิดด้วยตนเอง (Aha! Moments) ผ่าน Reinforcement Learning โดยไม่ต้องพึ่งพาข้อมูล SFT จากมนุษย์ในช่วงแรก
- โมเดลเรียนรู้ที่จะขยายกระบวนการคิด (Thinking Process) เพื่อแก้ปัญหาที่ซับซ้อนทางคณิตศาสตร์และตรรกะ

ความท้าทายในการตรวจสอบ (The Verifiability Challenge)




Outcome Reward Model (ORM)



ให้คะแนนที่ผลลัพธ์สุดท้าย (เน้นปลายทาง)


****Note:**** คำตอบที่ถูกอาจมาจากกระบวนการคิดที่ผิด

Process Reward Model (PRM)



ให้คะแนนทุกขั้นตอนของการคิด (เน้นวิธีการ)
ช่วยให้การให้เหตุผลแม่นยำยิ่งขึ้น

Pillar 4: Efficiency — การเพิ่มประสิทธิภาพทรัพยากร



1. Model Compression

Quantization: การลดความละเอียดของตัวเลข (เช่น 16-bit $\rightarrow$ 4-bit) เพื่อลดขนาดหน่วยความจำ



2. Parameter-Efficient Fine-Tuning (PEFT)

LoRA (Low-Rank Adaptation): การปรับแต่งโมเดลโดยเพิ่มพารามิเตอร์จำนวนน้อยเข้าไปแทนที่จะปรับโมเดลหลักทั้งหมด



3. Knowledge Distillation

การถ่ายทอดความรู้จากโมเดลใหญ่ (Teacher) สู่โมเดลเล็ก (Student)

Pillar 5: Integration – การเชื่อมต่อกับโลกภายนอก



RAG (Retrieval-Augmented Generation)

การดึงข้อมูลที่เป็นปัจจุบันจากฐานข้อมูล
ภายนอกมาช่วยในการตอบคำถาม
ลดอาการหลอนข้อมูล (Hallucination)

LLM Core



Multi-Modal Capabilities

การขยายขอบเขตจากข้อความสู่
รูปภาพ (Vision) และ เสียง (Audio)



Domain Adaptation

การปรับแต่งความรู้เฉพาะทาง เช่น
การแพทย์ (Medical) หรือ กฎหมาย
(Legal)

ข้อมูล (Data) – เชื้อเพลิงของการ Post-Training



Human-Labeled
Data

‘มีคุณภาพสูงแต่
แพงและขยาย
ขนาดได้ยาก’



**Synthetic Data &
Distilled Datasets**

‘แนวโน้มใหม่ในการใช้โมเดล
อัจฉริยะสร้างข้อมูลสอน
สำหรับโมเดลอื่น (Self-
Instruct)’

Implication: ช่วยแก้ปัญหาการขาดแคลนข้อมูลคุณภาพสูง (**Data Scarcity**)

การประยุกต์ใช้งานจริง (Real-World Applications)


Professional Domains



Professional Domains

ผู้ช่วยทางกฎหมาย (Legal),
การวินิจฉัยทางการแพทย์ (Medical)

Technical Reasoning



Technical Reasoning

การเขียนโค้ด (Code Generation),
การพิสูจน์ทางคณิตศาสตร์ (Math)

Interaction



Interaction

แชทบอทอัจฉริยะ (Dialogue),
ระบบแนะนำ (Recommendation)

บทสรุปและทิศทางในอนาคต (Future Directions)

Large Reasoning Models (LRMs)

การรวม RLHF เข้ากับความ
สามารถในการใช้เหตุผลจะ
เป็นมาตรฐานใหม่



Superalignment

ความท้าทายในการควบคุม
AI ที่ฉลาดกว่ามนุษย์



Unified Modality

การรวมทุกประสาทสัมผัส
(ภาพ/เสียง/ข้อความ) เป็น
หนึ่งเดียวอย่างสมบูรณ์



สรุป: วงจรแห่งการขัดเกลา (The Refinement Cycle)



Post-training คือขั้นตอนที่เปลี่ยนโมเดลทางภาษา
ให้กลายเป็นผลิตภัณฑ์ที่เปลี่ยนโลก