




Sci-LLMs: รุ่งอรุณแห่งวิทยาศาสตร์ปัญญาประดิษฐ์

จากรากฐานข้อมูลสู่พรมแดนแห่ง Agent อัจฉริยะ

วิวัฒนาการ 4 ยุคสมัยของโมเดลภาษาทางวิทยาศาสตร์ (2018-2025)


ยุค Transfer Learning (2018-2020)

ปรับแต่งโมเดล (SciBERT, BioBERT) เพื่อเข้าใจข้อความ




ยุค Scaling (2020-2022)

ขยายขนาดและบูรณาการความรู้ (Galactica)




ยุค Instruction Following (2022-2024)

เรียนรู้ตามคำสั่งและงานเฉพาะทาง (MedPaLM-2)



ยุค Agentic Science (2023-ปัจจุบัน)

ระบบตัวแทนอัจฉริยะที่ค้นพบสิ่งใหม่ได้เอง (Intern-S1)



Key Insight: เรากำลังเปลี่ยนผ่านจาก AI ที่เป็นเพียง 'เครื่องมือสืบค้น' ไปสู่ 'ผู้ร่วมวิจัย' (Co-scientist)


อนุกรมวิธานของข้อมูลวิทยาศาสตร์: ความซับซ้อนที่เหนือกว่าข้อความ

Textual (ข้อความ)




บทความวิจัย, บันทึกการทดลอง, สิทธิบัตร

Visual (ภาพ)




ภาพถ่ายดาราศาสตร์, ภาพสแกนการแพทย์,
กล้องจุลทรรศน์

Symbolic (สัญลักษณ์)



สูตรเคมี (SMILES), สมการคณิตศาสตร์,
โครงสร้างผลึก

Structured (โครงสร้าง)



ฐานข้อมูลยีน (GenBank), กราฟความรู้ (Knowledge Graphs)



Time-Series (อนุกรมเวลา)



คลื่นความโน้มถ่วง, EEG, ข้อมูลอุตุนิยมวิทยา


การถอดรหัสภาษาแห่งโมเลกุลและพันธุกรรม

Symbolic Representations (สัญลักษณ์)

Representation	Formaldehyde	Phenol
Molecular graph		
SMILES string	C=O	Oc1ccccc1
SELFIES string	[C]=[O]	[C]=[C][C]=[C] [C]=[C][Ring1] [Branch1][O]


→ **Insight:** โมเดลต้องเข้าใจ 'ไวยากรณ์' ทางเคมีเพื่อความถูกต้อง 100%

Multi-Omics Integration (มัลติโอมิกส์)




 **Insight:** การบูรณาการข้อมูลหลายระดับช่วยไขความลับกลไกของสิ่งมีชีวิต


ลำดับชั้นของความรู้วิทยาศาสตร์ (The Scientific Knowledge Hierarchy)



ภูมิทัศน์ของ Sci-LLMs: จากผู้รอบรู้สู่ผู้เชี่ยวชาญเฉพาะทาง



กรณีศึกษา: เคมีและวัสดุศาสตร์ (Chemistry & Materials Science)



Synthesis Planning

การวางแผนขั้นตอนการสังเคราะห์สารเคมีที่ซับซ้อน



Property Prediction

การทำนายคุณสมบัติของวัสดุใหม่ก่อนการทดลองจริง



Structure Generation

การออกแบบโครงสร้างผลึก (Crystal Structure) และโพลิเมอร์

Challenge: การจัดการกับ Search Space ขนาดมหาศาล และข้อจำกัดทางโครงสร้าง


กรณีศึกษา: วิทยาศาสตร์ชีวภาพและการแพทย์ (Life Sciences & Healthcare)

From Sequence to Structure



เข้าใจ Central Dogma (DNA → RNA → Protein) เพื่อการค้นพบยาใหม่

Clinical Reasoning



ระบบผู้ช่วยแพทย์วิเคราะห์ภาพถ่ายและประวัติผู้ป่วย (เช่น MedPaLM)

การวัดผลอัจฉริยภาพทางวิทยาศาสตร์ (Evaluation & Benchmarking)

แบบเดิม (Static Exams)

วัดความจำจากข้อสอบปรนัย
(MMLU, ScienceQA)

ข้อจำกัด: ไม่สะท้อนกระบวนการ
การวิจัยจริง



แบบใหม่ (Discovery-Oriented)

วัดกระบวนการค้นพบและก
ารแก้ปัญหา (SciBench,
ResearchBench)

เน้นการตั้งสมมติฐานและการ
ออกแบบการทดลอง



Methodology: LLM-as-a-Judge (ใช้โมเดลระดับสูงประเมินผลลัพธ์)


การออกแบบขั้นตอนการค้นพบจะเน้น ใช้โมเดลระดับสูงประเมินผลลัพธ์ และ
กรณเอนที่ระสากวนกานการวิจัยและเลมินผลลัพธ์

ความท้าทายด้านข้อมูล: อุปสรรคสำคัญของการพัฒนา



Scarcity of Negative Results

ผลการทดลองที่ล้มเหลว
ไม่ถูกตีพิมพ์ ทำให้ AI
เรียนรู้แต่ความสำเร็จ
(Bias)



Modality Gap

ข้อความมีมาก แต่
ข้อมูลดิบการทดลองคุณ
ภาพสูงยังขาดแคลน



Traceability Crisis

ปัญหาการตรวจสอบ
ย้อนกลับแหล่งที่มาแล
ะความน่าเชื่อถือ



Lack of AI-Readiness

ข้อมูลในห้องแล็บส่วน
ใหญ่ยังไม่ได้มาตรฐาน
สำหรับ AI


Prompt: สุ่มคสมัยแห่ง Scientific Agents



AI ที่มีความสามารถในการ '**คิด**' (Reason) และ '**กระทำ**' (Act) เพื่อขับเคลื่อนการวิจัย

- 1. Planning:** การวางแผนลำดับขั้นตอนการวิจัยที่ซับซ้อน
- 2. Tool Use:** การเรียกใช้เครื่องมือภายนอก (Simulation, Databases)
- 3. Memory:** การจดจำผลลัพธ์และแก้ไขข้อผิดพลาด (Self-correction)
- 4. Action:** สั่งการหุ่นยนต์เพื่อทำการทดลองจริง (Autonomous Lab)

ระบบนิเวศการค้นพบแบบวงรอบปิด (Closed-Loop Discovery Ecosystem)



อนาคตและความรับผิดชอบทางจริยธรรม

Autonomous Discovery

เป้าหมายสู่ห้องปฏิบัติการที่ขับเคลื่อนด้วยตนเองอย่างสมบูรณ์
(Fully Autonomous)



Data Standardization

สร้างมาตรฐานข้อมูลกลาง
สำหรับวิทยาศาสตร์ทั่วโลก
(Global Standards)




Ethical Governance

- ความปลอดภัยในการสังเคราะห์สาร (Safety)
- การป้องกันข้อมูลหลอน (Hallucination Risks)
- แนวทางกำกับดูแล AI (Responsible AI)



บทสรุป: บทเพลงแห่งความกล้าหาญของมนุษยชาติ




Beyond Text

ก้าวข้ามข้อความสู่สัญลักษณ์
และข้อมูลหลากหลายรูปแบบ



Co-evolution

ข้อมูลและโมเดลต้อง
วิวัฒนาการไปพร้อมกัน



Agentic Future

จากการสืบค้นข้อมูล
สู่การสร้างการค้นพบ

“บทเพลงของมนุษยชาติ คือบทเพลงแห่งความกล้าหาญ...
ในการขยายความเข้าใจทางวิทยาศาสตร์จากระดับจุลภาคสู่ระดับมหภาค”

เอกสารอ้างอิงและกิตติกรรมประกาศ

เอกสารอ้างอิงหลัก

Hu, M., et al. (2025). "A Survey of Scientific Large Language Models: From Data Foundations to Agent Frontiers." arXiv preprint preprint arXiv:2508.21148.

กิตติกรรมประกาศ

- 🧠 - Shanghai Artificial Intelligence Laboratory
- 🔗 - Intern Discovery Team
- 🔗 - Open Science Lab (Github: Awesome-Scientific-Datasets-and-LLMs)



Scan for Paper