





D-AR: ปฏิวัติการสร้างภาพด้วยการผสาน Autoregressive และ Diffusion

เปลี่ยนกระบวนการ Diffusion ให้เป็นแบบ “Next-Token Prediction” โดยไม่ต้องแก้ไขโครงสร้าง AR


Diffusion via Autoregressive Models

Autoregressive (AR)



- Examples: GPT-4, Llama
- Strengths: เก่งเรื่องข้อมูลลำดับ (Sequential), เร็ว (KV Cache), โครงสร้างพื้นฐานแข็งแกร่ง
- Weakness: จัดการข้อมูลภาพ 2D ได้ยาก

Diffusion Models



- Examples: Stable Diffusion, Flux
- Strengths: คุณภาพภาพสูง, จัดการสัญญาณต่อเนื่อง (Continuous) ได้ดี
- Weakness: ทำงานช้า (Dense computation), รวมกับ LLM ยาก

จะเกิดอะไรขึ้นถ้าเราสามารถรวม ‘ความเร็วและความฉลาด’ ของ AR เข้ากับ ‘คุณภาพ’ ของ Diffusion?


ความท้าทาย: เมื่อ "คำ" และ "ภาพ" พูดคนละภาษา

Traditional AR



Discrete / Linear


Traditional
Diffusion



Continuous / 2D

Solution: D-AR เปลี่ยนมุมมองใหม่ มองกระบวนการ Diffusion เป็น "ลำดับของเหตุการณ์" (Sequence) ที่แปลงเป็น **Token** ได้


นวัตกรรมหลัก: Sequential Diffusion Tokenizer



1. แปลงภาพเป็น Sequence
2. Token แต่ละกลุ่ม = ขั้นตอนการลด Noise
3. เริ่มจาก หยาบ (Coarse) → ละเอียต (Fine)

จากโครงสร้างสู่รายละเอียด: การเล่าเรื่องด้วยภาพ

Early Tokens (Global Semantics)



Mid Tokens (Structure)



Later Tokens (Local Details)




เปรียบเสมือนศิลปินวาดภาพ: เริ่มจากร่างโครงสร้างใหญ่ แล้วค่อยๆ เติมรายละเอียด
AR Model สามารถทำนาย Token ถัดไปได้ง่าย เพราะสอดคล้องกับตรรกะธรรมชาติ

พลังของ "Vanilla" Autoregressive Modeling

ไม่ต้องแก้ Architecture ไม่ต้องแก้ Attention Mask

Standard Next-Token Prediction

ใช้โมเดลภาษาแทนได้ทันที




Native Optimization

รองรับ KV Cache เต็มรูปแบบ

Simplicity

ใช้ Loss Function แบบ Cross Entropy ธรรมดา


D-AR Pipeline: การทำงานร่วมกันของสองระบบ



Noise




Mid



Final

จุดต่างที่เหนือกว่า (Key Differentiators)

Method	Approach	Drawback
MAR / SEED-X	ปรับแก้ AR Architecture หรือใช้ Diffusion ทุกขั้นตอน	ซับซ้อนและช้า
DART	Denoise ภาพเต็ม ในทุกขั้นตอน AR	กินทรัพยากรสูง
D-AR (Ours)	ใช้ Vanilla AR (Discrete I/O) + Diffusion Tokenizer	เบา, เร็ว, และเข้ากันได้กับ LLM



Feature 1: Streaming Preview

เห็นภาพร่างได้ทันที ไม่ต้องรอให้เสร็จ 100%



User Experience ที่ดีกว่า เห็นผลลัพธ์คร่าวๆ ได้ในเสี้ยววินาที

Feature 2: Zero-Shot Layout Control


ควบคุมโครงสร้างภาพได้โดยไม่ต้องเทรนใหม่



Prefix Tokens
(Structure)




Prompt:
Golden Retriever




โมเดลรักษาโครงสร้างหลัก
(Layout) ของภาพต้นแบบ
แต่เปลี่ยนรายละเอียดตามคำสั่ง

ประสิทธิภาพที่พิสูจน์ได้ (Quantitative Results)



D-AR ให้คุณภาพที่สูงกว่าในขณะที่ใช้ทรัพยากรน้อยกว่า

ความคมชัดและความหลากหลาย



Uncurated Samples from
ImageNet 256x256

ความยืดหยุ่นของโมเดล (Scalability)

Tokenizer

300M Params (Lightweight)

D-AR-L

343M Params | FID 2.44

D-AR-XL

775M Params | FID 2.09

โมเดลยิ่งใหญ่ ประสิทธิภาพยิ่งสูงขึ้น (Scaling Law holds true)

บทสรุปและอนาคต



Seamless Integration

เชื่อม AR และ Diffusion
โดยไม่ต้องรื้อระบบเดิม



High Performance

เร็ว (KV Cache), สวย
(Diffusion Decoder),
ควบคุมได้ (Zero-shot)



Future Vision

สู่ Unified Multimodal
LLMs ที่สร้างภาพได้
โดยกำเนิด

เอกสารอ้างอิง (References)

Paper: D-AR: Diffusion via Autoregressive Models ([arXiv:2505.23660](https://arxiv.org/abs/2505.23660))

Authors: Ziteng Gao, Mike Zheng Shou

Institution: Show Lab, National University of Singapore

Project Link: github.com/showlab/D-AR



Scan for Code & Models