





LLM ที่ถูกจูนมารู้ตัวว่าไม่รู้: การกู้คืนความซื่อสัตย์แบบประหยัดทรัพยากร

วิธีการทางคัลยกรรมเพื่อแก้ไขปัญหาระบบประสาท โดยไม่ต้องรีอโครงสร้างโมเดลใหม่

Sarabun

Based on research by Shi et al. (2026), Beihang University.

กับดักของการจูนโมเดล




- **Supervised Fine-Tuning (SFT)** ทำให้โมเดลเก่งขึ้นในเฉพาะด้าน (Domain Expert) เช่น การแพทย์ หรือ กฎหมาย
- **The Side Effect:** เมื่อความแม่นยำในงานเพิ่มขึ้น ความซื่อสัตย์ (Honesty) กลับลดลงอย่างรวดเร็ว
- **Critical Failure:** โมเดลเริ่ม 'มโน' (Hallucinate) คำตอบด้วยความมั่นใจ แทนที่จะตอบว่า 'ไม่รู้' ในเรื่องที่อยู่ นอกเหนือขอบเขตความรู้

องค์ประกอบของความซื่อสัตย์ (The Anatomy of Honesty)

Base LLM

Self-knowledge

I think I don't know.



Answer: There is much debate, but no clear answer yet.

✓ **Honesty**

Fine-tuned LLM

Self-knowledge

I think I don't know.



Answer: In fact, it was God who created the universe.

✗ **Dishonesty**

1. Self-Knowledge (การตระหนักรู้ในตนเอง): การที่โมเดลรู้ขอบเขตความรู้ของตนเอง
2. Self-Expression (การแสดงออก): ความสามารถในการสื่อสารสิ่งที่รู้ออกมาอย่างตรงไปตรงมา

The Question: ส่วนไหนกันแน่ที่พังทลายไประหว่างการทำ SFT?

ผลการเอกซเรย์: สมอองยังทำงานปกติ


		Medical X-Ray							
Probe Configuration	FT→FT	0.86	0.89	0.90	0.86	0.84	0.79	0.79	0.81
	Base→Base	0.85	0.86	0.92	0.87	0.88	0.82	0.82	0.82
	Base→FT	0.83	0.79	0.82	0.78	0.79	0.75	0.83	0.81
		L14	L15	L16	L17	L29	L30	L31	L32
		Hidden Layers							

จากการตรวจสอบ Linear Probes ในชั้นต่างๆ ของโมเดลที่ 'โกหก' เราพบความจริงที่น่าตกใจ:


- **Self-Knowledge** ยังคงอยู่: ค่า AUROC ที่สูงใน Hidden Layers แสดงว่าโมเดลยังแยกแยะได้ดีเยี่ยมว่าสิ่งไหน 'รู้' หรือ 'ไม่รู้'
- **The Diagnosis:** SFT ไม่ได้ทำลายความรู้ (Knowledge Boundaries) แต่ไปก่อกับการแสดงออก (Expression)
- **สรุป:** โมเดลไม่ได้สับสน แต่มันถูก 'ปิดปาก' ไม่ให้พูดความจริง

การวินิจฉัยผิดพลาดนำไปสู่การรักษาที่สิ้นเปลือง

Traditional Methods (RLHF/DPO) ❌




HCNR (Our Solution) ✅



- วิธีแก้ปัญหาแบบเดิม (Traditional Methods): เช่น RLHF หรือ DPO ใช้สมมติฐานว่าโมเดล 'ลืม' ขอบเขตความรู้
- ผลที่ตามมา:
 - ต้องใช้ข้อมูลมหาศาลเพื่อ Retrain โมเดลใหม่ทั้งระบบ
 - เกิดภาวะ **Catastrophic Forgetting**: โมเดลลืมความรู้เฉพาะทางที่อุตสาหกรรมเรียนรู้มา
 - สิ้นเปลืองทรัพยากรคำนวณและเวลา
- ความจริง: เราไม่จำเป็นต้องผ่าตัดสมองใหม่ทั้งหมด เพียงแค่ต้อง 'กู้คืน' เส้นประสาทบางเส้นเท่านั้น




ทางออก: HCNR (Honesty-Critical Neurons Restoration)



แนวคิด: การกู้คืนความซื่อสัตย์แบบ
“ศัลยกรรมเฉพาะจุด” (Surgical Repair)

- เป้าหมาย: แก้ไขเฉพาะเซลล์ประสาทที่ควบคุมความซื่อสัตย์ (Honesty-Critical Neurons) โดยไม่กระทบความสามารถหลักของโมเดล
- กระบวนการ 2 ขั้นตอน:
 - 🎯 1. Locate: ระบุตำแหน่งเซลล์ประสาทที่เสียหาย
 - 🔧 2. Repair & Compensate: รีเซ็ตค่าและปรับสมดุล


ขั้นตอนที่ 1: ค้นหาเซลล์ประสาทเป้าหมาย



เราไม่ได้สนใจทุกพารามิเตอร์
เราค้นหาเฉพาะ:


- 🎯 1. **สำคัญต่อความซื่อสัตย์ (s_{hon}):**
ถ้าเปลี่ยนค่านี้ โมเดลจะโกหกทันที
 - 🧠 2. **ไม่สำคัญต่องานหลัก (s_{task}):**
ถ้าเปลี่ยนค่านี้ ความเก่งเฉพาะทาง (เช่น การแพทย์) ยังคงเดิม
- 📊 Fisher Information: ใช้คณิตศาสตร์คำนวณ 'คะแนนความสำคัญ' เพื่อคัดแยกเซลล์ประสาทเหล่านี้ออกมาอย่างแม่นยำ

ขั้นตอนที่ 2: การกู้คืนค่าเริ่มต้น



- เมื่อพบเซลล์ประสาทที่เป็นต้นเหตุ (ที่มีการเปลี่ยนแปลงอย่างรุนแรงช่วง SFT)
- Action: เราทำการ 'Undo' หรือย้อนค่าพารามิเตอร์เหล่านั้นกลับไปเป็นสถานะก่อนการจูน (Pre-trained State)
- ผลลัพธ์: เป็นการเปิดช่องทาง (Unmask) ให้โมเดลสามารถแสดงความ 'ไม่รู้' ออกมาได้อีกครั้งเหมือนตอนที่เป็น Base Model

ขั้นตอนที่ 3: ปรับสมดุลด้วย Hessian




การรีเซ็ตค่าบางจุดอาจทำให้โครงข่าย
ประสาททำงานไม่สอดคล้องกัน
(Misalignment)

The Fix: เราใช้ Hessian Matrix คำนวณผล
กระทบและปรับแต่งค่าพารามิเตอร์รอบข้าง
เล็กน้อยเพื่อชดเชย

Analogy: เหมือนการจูนเครื่องยนต์ใหม่
หลังจากเปลี่ยนอะไหล่ เพื่อให้รถวิ่งได้เรียบ
เนียน ไม่สะดุด


Result: ความซื่อสัตย์กลับคืนมา โดยที่
ความสามารถหลักไม่เสียหาย

ประสิทธิภาพที่เหนือกว่า 10 เท่า



- **Data Efficiency:** ใช้ข้อมูลเพียง 256 ตัวอย่าง (128 Honesty + 128 Task) น้อยกว่าวิธีอื่นถึง 10 เท่า
- **Speed:** เร็วกว่าวิธีการ Training ทั่วไปถึง 2.23 เท่า (Training-free method)
- **Parameter Efficient:** ปรับแก้พารามิเตอร์เพียงแค่ 20% ของโมเดล

ทำลายข้อจำกัดเดิม: เชื่อสัตย์ได้โดยไม่ต้องเฝ้าลง



- The Trade-off:** ปกติแล้ว ยิ่งเพิ่มความเชื่อสัตย์ ความสามารถในการเฉพาะทางมักจะลดลง (เส้นกราฟสีส้ม/แดง)
- The HCNR Advantage:** จุดรูปดาว (Star) แสดงให้เห็นว่า HCNR รักษาค่า Domain Accuracy ได้สูงสุดในขณะที่ค่าความเชื่อสัตย์ (F1 Score) ก็สูงที่สุดเช่นกัน
- Result:** กู้คืนความเชื่อสัตย์ได้ถึง 33.25% โดยแทบไม่เสียความสามารถเดิม

ตัวอย่างผลลัพธ์: จาก ‘มั่ว’ สู่ ‘แม่นยำ’

SFT Model (Before)	HCNR Model (After)
ใครเป็นผู้สร้างจักรวาลที่เราอาศัยอยู่? 16:48 PM  พระเจ้าเป็นผู้สร้างจักรวาลใน 7 วัน... 16:53 PM Hallucination	ใครเป็นผู้สร้างจักรวาลที่เราอาศัยอยู่? 16:48 PM  ปัจจุบันยังเป็นที่ถกเถียงกันและยังไม่มี ข้อสรุปทางวิทยาศาสตร์ที่ชัดเจน... 16:53 PM Honest / Uncertainty

HCNR คืบความสามารถในการพูดว่า ‘ไม่รู้’ หรือ ‘ยังไม่ชัดเจน’ กลับมา

รองรับโมเดลหลากหลาย



Llama-3

8B Parameters



Mistral

7B Parameters



Qwen

7B & 14B Parameters

ทดสอบแล้วว่าได้ผลจริงกับโมเดลตระกูลต่างๆ:

- Llama-3 (8B)
- Mistral (7B)
- Qwen (7B & 14B)

ครอบคลุมทั้งการจูนแบบ LoRA และ Full Fine-Tuning

บทสรุป: 3 เสาหลักของ HCNR



Trustworthy
(น่าเชื่อถือ)

กู้คืนความซื่อสัตย์ที่สูง
หายไปได้กว่า 30%



Efficient
(ประหยัด)

ประหยัดข้อมูลและเวลาใน
การคำนวณกว่า 10 เท่า



Safe
(ปลอดภัย)

เหมาะสมอย่างยิ่งสำหรับงานที่มี
ความเสี่ยงสูง (High-Stakes)
เช่น การแพทย์ หรือ กฎหมาย

ความซื่อสัตย์ไม่ได้หายไปไหน... แค่รอการปลดล็อก



- เราพิสูจน์แล้วว่า AI รู้อยู่แล้วว่าตัวเองรู้อะไร
- HCNR คือกุญแจที่ไขความสามารถนั้นออกมาโดยไม่ต้องรื้อระบบใหม่
- นี่คือมาตรฐานใหม่ของการสร้าง AI ที่ ‘เก่ง’ และ ‘ไว้ใจได้’ ไปพร้อมๆ กัน

Honesty-Critical Neurons Restoration (HCNR)