



ต้นกำเนิดของ Self-Attention: จาก Infinite Feature Selection สู่ Transformers

การสำรวจรากฐานทางคณิตศาสตร์ของ
Affinity-Based Computation

เรียบเรียงจากงานวิจัยโดย Giorgio Roffo, 2025




Transformers คือมาตรฐานใหม่ของ AI ยุคปัจจุบัน




- สถาปัตยกรรม **Transformers** เป็นหัวใจสำคัญของโมเดลระดับโลกไม่ว่าจะเป็น LLMs, Computer Vision, หรือชีวสารสนเทศ
- ความสำเร็จนี้ไม่ได้เกิดขึ้นจากเวทมนตร์ แต่เกิดจากกลไกทางคณิตศาสตร์ที่เรียกว่า **'Self-Attention'** ซึ่งทำหน้าที่จัดการการไหลเวียนของข้อมูล
- Key Insight: แต่กลไกนี้เป็นสิ่งใหม่จริงหรือ? หรือเป็นเพียงร่างอวตารใหม่ของหลักการที่มีมาก่อนแล้ว?

หัวใจสำคัญคือ 'Pairwise Affinity Matrix' (A)



- ก่อนจะพูดถึงโมเดล เราต้องเข้าใจคณิตศาสตร์พื้นฐาน: **Affinity Matrix** ($A \in \mathbb{R}^{N \times N}$)
- มันคือตารางที่ระบุความสัมพันธ์ระหว่างองค์ประกอบทุกคู่ (All-pairs) ไม่ว่าจะเป็น Pixels, Tokens หรือ Features
- **นิยาม (Definition):** ค่า A_{ij} ระบุว่าองค์ประกอบ i มีความเกี่ยวข้องหรือควร 'ให้ความสนใจ' กับองค์ประกอบ j มากเพียงใด


Infinite Feature Selection (2015): บรรพบุรุษที่ถูกมองข้าม



Feature Graph (Fully Connected)


- ในปี 2015, Roffo et al. นำเสนอ **Inf-FS** เพื่อแก้ปัญหา Feature Selection
- **แนวคิดหลัก:** แทนที่จะเลือก Feature แบบแยกเดี่ยว Inf-FS สร้าง **Fully Connected Graph** ของ Features ทั้งหมด
- แต่ละเส้นเชื่อม (Edge) คือค่า Affinity ที่บอกว่า Feature สองตัวมีความสัมพันธ์กันอย่างไร
- นี่คือการใช้ Global Context เพื่อประเมินความสำคัญของข้อมูล ก่อนยุคของ Transformers

คณิตศาสตร์ของการเชื่อมโยงไร้ที่สิ้นสุด



- Inf-FS ไม่ได้ดูแค่เพื่อนบ้านใกล้เคียง แต่คำนวณผลรวมของเส้นทาง (Paths) ทั้งหมดที่เดินไปได้ในกราฟ
- **ความหมาย:** A คือความสัมพันธ์ทางตรง, A^2 คือความสัมพันธ์ผ่านตัวกลาง
- ผลลัพธ์คือค่าความสำคัญที่กลั่นกรองจาก **Global Structure** ของข้อมูลทั้งหมด

2017: การกำเนิดของ Transformers และ QK^T




- Vaswani et al. นำเสนอ Transformer ซึ่งตัด Recurrence ทิ้งและใช้ Self-Attention
- สูตร (Formula):
$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V$$
- จุดเชื่อมโยง: เทอม QK^T ก็คือ **Dynamic Affinity Matrix (A)** นั้นเอง
- มันคือการสร้างกราฟความสัมพันธ์ระหว่าง Tokens เพื่อ 'Re-weight' ข้อมูลตามบริบท

การเปรียบเทียบเชิงโครงสร้าง (Structural Comparison)

	Infinite Feature Selection (2015)	Transformer Self-Attention (2017)
Underlying Graph	Fully-connected Feature graph $(A \in \mathbb{R}^{d \times d})$	Fully-connected Token graph $(A \in \mathbb{R}^{n \times n})$
Score Computation	Handcrafted (Correlation) or Learned	Learned Dot Product (QK^T)
Interaction Depth	Multi-hop (Infinite path series)	Single-hop per layer (Stacked layers mimic multi-hop)
Goal	Ranking/Selection (Filtering)	Representation Learning (Mixing)


วิวัฒนาการจาก Static สู่ Dynamic

Static Affinity (Inf-FS)



- **Inf-FS (Static):** เมทริกซ์ A ถูกคำนวณจากทั้ง Dataset เพื่อหาความสัมพันธ์สากลของ Features

Dynamic Affinity (Attention)



- **Self-Attention (Dynamic):** เมทริกซ์ A ถูกสร้างขึ้นใหม่ในทุกๆ Forward Pass ตามข้อมูล Input เฉพาะหน้า


บทสรุป: Attention คือ Feature Selection ที่ **‘ปรับตัวตามบริบท’ (Context-Aware)** และเกิดขึ้นแบบ Real-time

เส้นเวลาของแนวคิด Affinity-Based Reasoning



วิวัฒนาการของการใช้ Pairwise Matrix เพื่อจัดการข้อมูล


ภาษาศาสตร์ของข้อมูล: ภาพ, กราฟ, และข้อความ



Core Mechanism: Pairwise Affinity (A)


- **Computer Vision:** Non-Local Neural Networks (2018) ใช้ $f(x_i, x_j)$ คำนวณความสัมพันธ์ระหว่าง Pixels เหมือน Self-Attention
- **Graph Learning:** GAT เรียนรู้ที่จะ “ให้น้ำหนัก” เพื่อนบ้านในกราฟต่างกัน
- ไม่ว่าข้อมูลจะเป็นรูปแบบใด หัวใจคือการคำนวณ **Pairwise Affinity (A)**

Feature Selection คือ 'Hard Attention'



- **Soft Attention:** ใช้ Softmax เพื่อกระจายน้ำหนัก (0.1, 0.7, 0.2) เป็นการผสมผสานข้อมูล
- **Hard Selection:** เป็นกรณีสุดโต่งของ Attention ที่น้ำหนักเป็น Binary (0 หรือ 1) คือเลือกหรือไม่เลือก
- **ความเชื่อมโยง:** โมเดลยุคใหม่เริ่มใช้ Feature Selection Gates (FSG) ผสมผสานแนวคิดทั้งสองเพื่อความแม่นยำและการอธิบายผลได้

มุมมองแบบรวมศูนย์ (A Unified View)



- Self-Attention ไม่ใช่สิ่งแปลกปลอม แต่เป็น '**กรณีศึกษาเฉพาะ (Specific Case)**' ของ Infinite Feature Selection
- เมื่อ A ถูกเรียนรู้ผ่าน Token Similarities และจำกัดการคำนวณที่ Single-hop → เราจะได้ Transformers
- โครงสร้างหลักยังคงเดิม: **Reasoning over Pairwise Relationships**

“

การวิวัฒนาการของ Self-Attention
สะท้อนถึงหลักการที่กว้างกว่า: การใช้ความ
(Pairwise Affinities) คือคุณสมบัติสำคัญในการ
สร้างโครงสร้างให้กับข้อมูลที่ซับซ้อน

”

จาก Inf-FS สู่ Transformers: คณิตศาสตร์เดียวกัน
ในบริบทที่ต่างกัน

เอกสารอ้างอิงและงานวิจัยที่เกี่ยวข้อง



Inf-FS: Roffo et al., 'Infinite Feature Selection', ICCV 2015 / TPAMI 2021



Transformers: Vaswani et al., 'Attention Is All You Need', NeurIPS 2017



Non-Local NN: Wang et al., CVPR 2018



Source Paper: "The Origin of Self-Attention" (arXiv:2507.14560)