


# สถาปัตยกรรม LLM ยุคใหม่: จาก DeepSeek V3 สู่ Mistral 3 Large



เจาะลึกวิวัฒนาการและการออกแบบโมเดลภาษาขนาดใหญ่ในปี 2025-2026



“7 ปีหลังจาก GPT-2 โครงสร้างภายนอกอาจดูคล้ายเดิม แต่เครื่องยนต์ภายในเปลี่ยนไปอย่างสิ้นเชิงเพื่อเป้าหมายเดียว: *Efficiency at Scale*”


# ปริศนาแห่งการพัฒนา: ขนาดไม่ใช่คำตอบเดียวอีกต่อไป

ยุคแห่งพลังดิบ (Brute Force)  
Sarabun Regular



DeepSeek V3: 671B Total Params → 37B Active Params  
ประสิทธิภาพสูงเหมือนโมเดลเล็ก แต่ฉลาดเหมือนโมเดลยักษ์


# การคำนวณแบบ Sparse: ยุคแห่ง Mixture-of-Experts (MoE)



## DeepSeek V3

Granular Experts


256 Total Experts  
8 Active + 1 Shared Expert



## Llama 4

Coarse Experts


Fewer, Larger Experts  
8 Active



## Qwen3 (MoE)


Simplified Routing

No Shared Expert  
Pure Routing




MoE ช่วยให้เราได้ 'ความรู้' (Total Params) มหาศาล โดยไม่ต้องจ่าย 'ค่าพลังงาน' (Active Params) เพิ่มขึ้นในการคิดแต่ละครั้ง

# ปลดล็อกคอขวดหน่วยความจำ: วิวัฒนาการของ Attention



MLA บีบอัด KV Cache ลงอย่างมหาศาล ทำให้ DeepSeek V3 จัดการ Context ยาวๆ ได้ดีกว่า GQA โดยไม่เสียคุณภาพ

# การจัดการบริบท: Sliding Windows และ Normalization




## Sliding Window Attention

Gemma 3 ใช้ Global Attention สลับกับ Sliding Window ในอัตราส่วน 1:5


- ลดการใช้หน่วยความจำอย่างมีนัยสำคัญ

## Normalization Tweaks



เพิ่มความเสถียรในการเทรน (Training Stability)

# The Titan: DeepSeek V3 & R1 - ผู้นำเทรอนด์สถาปัตยกรรม



**DeepSeek R1**


คือโมเดล V3  
ที่ผ่านกระบวนการ  
Post-training  
ด้วย RL  
เพื่อสร้าง  
ความสามารถในการ  
‘คิดหาเหตุผล’  
(Reasoning)

“DeepSeek พิสูจน์ว่าสถาปัตยกรรมที่ฉลาดกว่า (Smart Architecture)  
สามารถเอาชนะพลังประมวลผลดิบ (Raw Compute) ได้”

# ผู้ทำชิงสาย Open Weight: Llama 4 และ Qwen3

## Llama 4

The Conservative Powerhouse




### STATS:

- Architecture: Classic MoE + GQA
- Strategy: High Stability / Few Experts
- Active Params: **17B (Efficient)**
- Total Params: **405B Density Equivalent**

## Qwen3

The Versatile Fighter




### STATS:

- Variants: **Dense (Deep)** & **MoE (Wide)**
- Innovation: **DeltaNet** (Linear Attention in Qwen3-Next)
- Performance: **0.6B** outperforms old Llama 3 **1B**


# ต้นแบบแห่งความโปร่งใส: OLMo 2/3 และ SmolLM3

โมเดลเหล่านี้คือ ‘ห้องเรียน’ สำหรับนักวิจัย เปิดเผยทุกรายละเอียดการฝึก

## NoPE (No Positional Embeddings)



Causal Mask



NoPE uses the Causal Mask to learn order implicitly.

## SmolLM3


- NoPE leads to better **Length Generalization**.
- เรียนรู้ลำดับจากบริบท ไม่ใช่จากตัวเลขตำแหน่ง

## OLMo 2

- Stability Focus: **RMSNorm** placement optimized to prevent spikes.


# อาณาจักรประสิทธิภาพ: Gemma 3 และ Mistral 3

## Gemma 3n (Mobile Focus)




Per-Layer Embeddings (PLE) - Streaming weights to save GPU memory.  
JetBrains Mono: (Efficient)

## Mistral 3 Large




DeepSeek-style MoE optimized for NVIDIA Blackwell chips.  
High throughput, low latency.  
JetBrains Mono: (MoE)

## MiniMax M2



Extreme Sparsity: Only 4% of parameters active per token!  
JetBrains Mono  
(10B active out of ~230B)

# การกลับมาของ Linear Attention: ทลายกำแพง $N^2$



## **\*\*The Players\*\***


- Qwen3-Next (DeltaNet)
- Kimi Linear (Delta Attention)

## **\*\*The Trade-off\*\***

แลกความแม่นยำ (Recall Precision) เล็กน้อย  
เพื่อแลกกับความเร็วและ Context ที่ไม่จำกัด

# ยุคแห่งลูกผสม: Transformer + SSM Hybrid


## The Zipper

Technical  
JetBrains Mono

**NVIDIA Nemotron 3**  
Interleaves Mamba-2  
with MoE.

Mamba handles flow;  
MoE handles knowledge.

**Transformer / MoE Blocks**  
Knowledge/Reasoning



**Mamba / SSM Blocks**  
Flow/Efficiency


### Qwen3-Next

Ratio 3:1 (3 DeltaNet :  
1 Gated Attention).

Maintains precision  
while boosting speed.

# กลไกเบื้องหลังความเร็ว: Multi-Token Prediction (MTP)

Standard Prediction



MTP  
(DeepSeek/Qwen3)




➡ **Training:** เรียนรู้ได้เร็วกว่า (Faster Convergence)

➡ **Inference:** Speculative Decoding - เดาคำล่วงหน้าเพื่อความเร็วในการตอบโต้

# ตารางสรุปสถาปัตยกรรม LLM ปี 2026

| Model       | Type   | Attention          | Active Params | Feature                |
|-------------|--------|--------------------|---------------|------------------------|
| DeepSeek V3 | MoE    | MLA                | 37B           | MTP / Shared Expert    |
| Llama 4     | MoE    | GQA                | 17B           | Conservative Stability |
| Gemma 3     | Dense  | GQA + Sliding      | N/A           | Local Attention        |
| Qwen3-Next  | Hybrid | DeltaNet           | Variable      | Linear Speed           |
| MiniMax M2  | MoE    | GQA + Partial RoPE | 10B           | Extreme Sparsity (4%)  |

# การเลือกเครื่องมือให้เหมาะกับงาน




# บทสรุป: สู่ยุคแห่งความเชี่ยวชาญเฉพาะด้าน



## Sparsity/MoE

- **One Size Fits None**

ไม่มีสถาปัตยกรรมเดียวที่ชนะทุกสนาม



## Memory/Attention

- **Architecture is Routing**

เส้นแบ่งระหว่าง ‘โครงสร้างโมเดล’  
และ ‘การจัดเส้นทางข้อมูล’  
(Routing) กำลังจางหายไป



## Linear/Hybrid

- **Efficiency is the new Moat**

ใครจัดการ Memory และ Active  
Params ได้ดีกว่า คือผู้ชนะ

“ในปี 2026 เราไม่ได้สร้างสมองที่ใหญ่ขึ้น  
แต่เรากำลังสร้างสมองที่รู้จักเลือกใช้พลังงานของตัวเอง”