

จาก Token สู่ความคิด: สิ่งที่แลกมาด้วย "ความหมาย"



เจาะลึกความต่างระหว่างโครงสร้างความรู้ของมนุษย์และ LLM
ผ่านเลนส์ Information Bottleneck


เมื่อ AI พูดว่า ‘นก’ มันคิดเหมือนเราหรือไม่?

Human Data



มนุษย์ (Human): เราจัดระเบียบความรู้โดยเน้น ‘ความหมาย’ (Meaning) คำว่า ‘นก’ ไม่ใช่แค่ป้ายชื่อ แต่เชื่อมโยงกับคุณสมบัติเช่น บินได้, มีขน, วางไข่

LLM Representation Pipeline




LLM: โมเดลภาษาจัดระเบียบข้อมูลโดยเน้น ‘การบีบอัด’ (Compression) เพื่อลดจำนวนบิตที่ใช้ในการเก็บข้อมูลให้ได้มากที่สุด

คำถามสำคัญ: การบีบอัดข้อมูลที่สมบูรณ์แบบแลกมาด้วยการสูญเสียโครงสร้างสร้างความหมายหรือไม่?


การวัดผลทางปัญญา: เมื่อโมเดลภาษาปะทะจิตวิทยาความรู้ความเข้าใจ

ผู้ท้าชิง (The Contenders)




- 40+ โมเดล (Llama, GPT, BERT, Gemma, Mistral, etc.)
- ขนาดตั้งแต่ 300M ถึง 72B พารามิเตอร์
- ครอบคลุมทั้ง Encoder และ Decoder Architectures

เกณฑ์การตัดสิน (Cognitive Benchmarks)



- ข้อมูลจากงานวิจัยคลาสสิก (Rosch 1973/1975, McCloskey 1978)
- 1,049 รายการ (Items) ใน 34 หมวดหมู่
- วัดผลทั้ง 'การเป็นสมาชิกกลุ่ม' (Membership) และ 'ระดับความเป็นตัวแทน' (Typicality)

สิ่งที่เหมือนกัน: LLM สามารถแยกแยะหมวดหมู่ได้ดีเยี่ยม




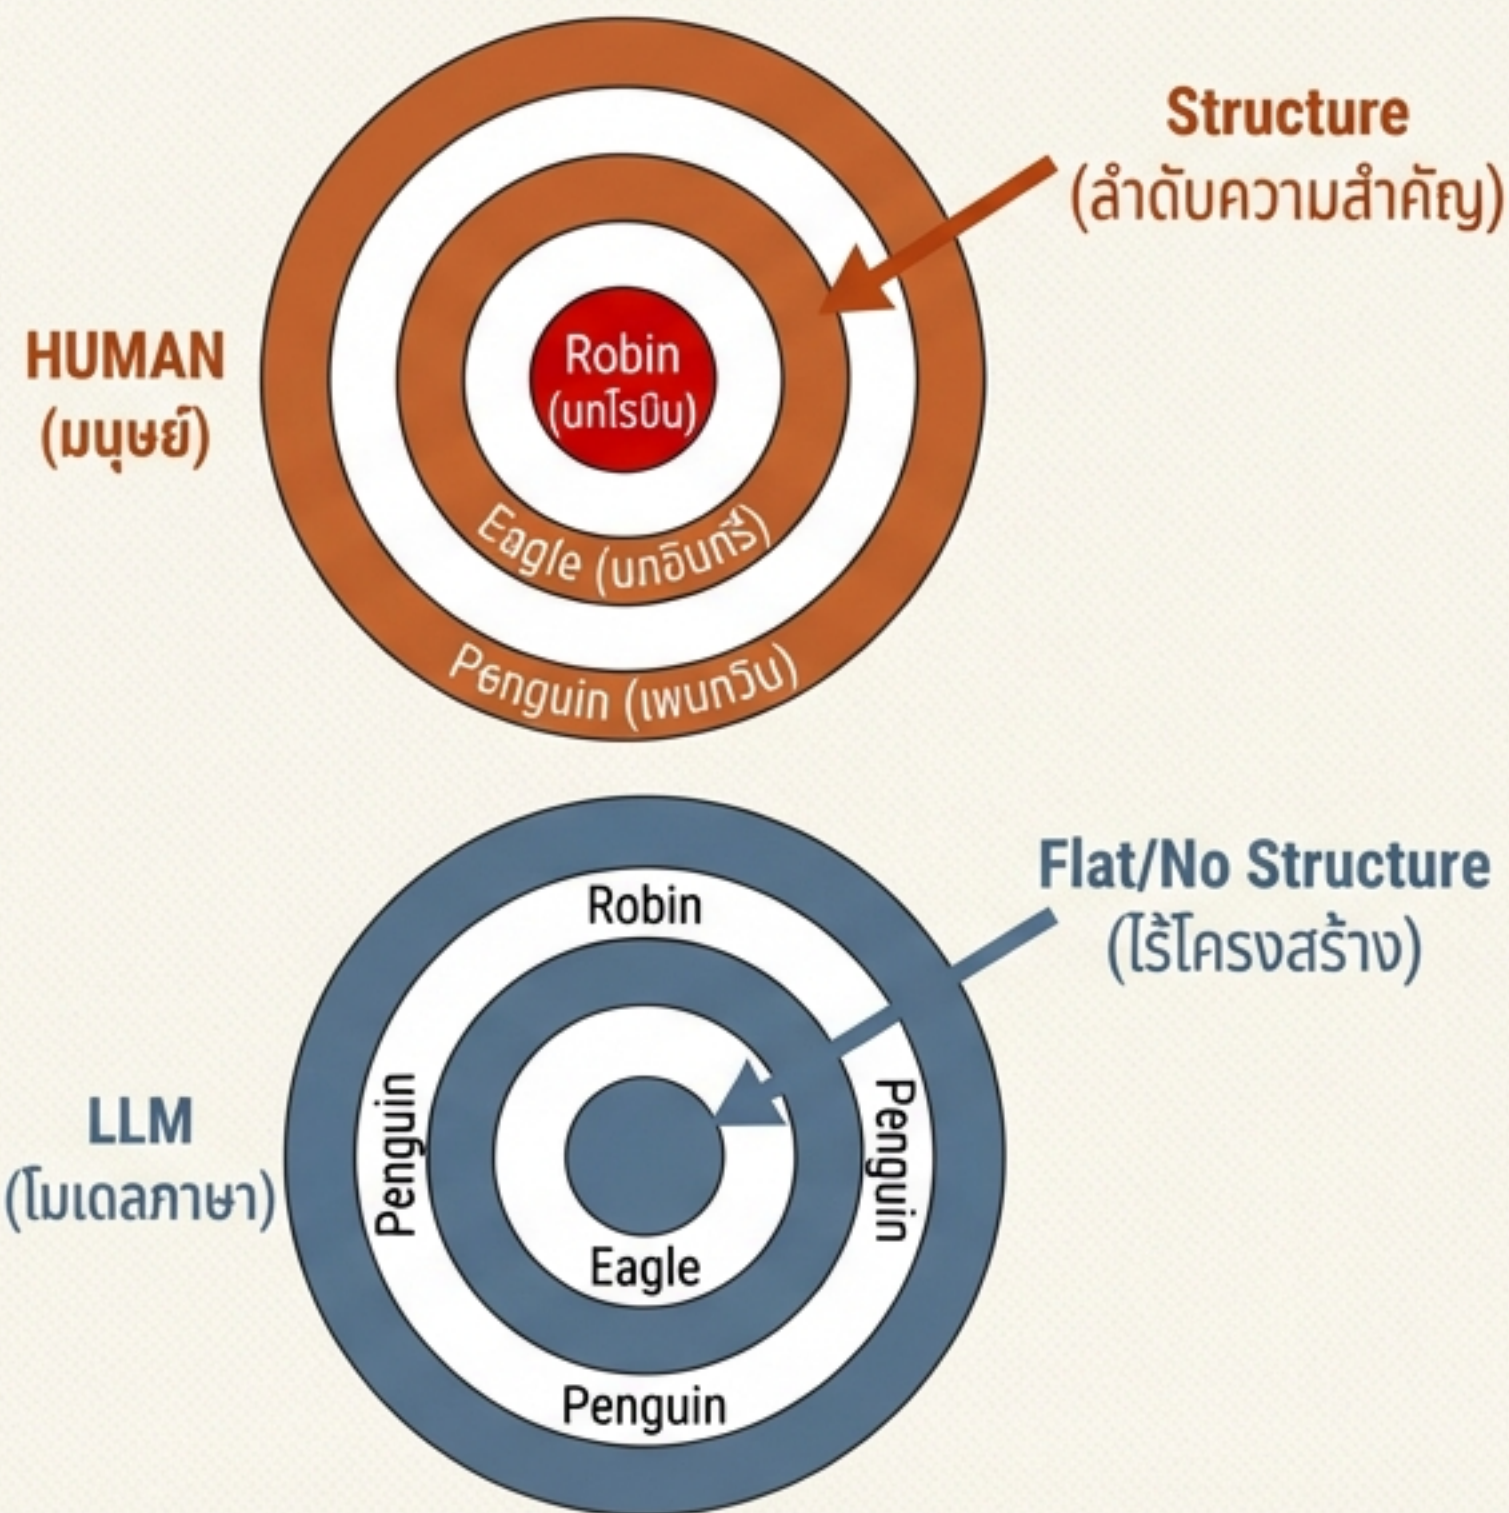
ผลลัพธ์: ไม่ว่าจะเป็นโมเดลขนาดเล็กหรือใหญ่ LLM สามารถจับกลุ่มคำ (Clustering) ได้ตรงกับหมวดหมู่ของมนุษย์

ตัวอย่าง: AI สามารถแยก 'เก้าอี้' ออกจาก 'ผลไม้' และ 'นก' ออกจาก 'สัตว์เลื้อยลูกเต๋ยนม' ได้อย่างถูกต้อง

Data Point: ค่า Adjusted Mutual Information (AMI) อยู่ที่ประมาณ 0.55 ซึ่งสูงกว่าการเดาสุ่มอย่างมีนัยสำคัญ


สรุป: LLM สอบผ่านในระดับ 'ขอบเขตของคำ' (Categorical Boundaries)

ภาพลวงตาที่แตกสลาย: ความล้มเหลวในการเข้าใจ "ลำดับความสำคัญ"




- **มนุษย์:** มองว่า 'นกโรบิน' มีความเป็นนกลมากกว่า 'เพนกวิน' (Prototype Theory)
- **LLM:** มองเห็นความสัมพันธ์แบบ 'แบนราบ' ขาดโครงสร้างจุดศูนย์กลางที่ชัดเจน
- **Insight:** ค่าสหสัมพันธ์ต่ำมาก ($\rho < 0.2$) ในเกือบทุกโมเดลยุคใหม่ แสดงว่า AI จับกลุ่มได้ แต่ไม่เข้าใจ 'ความหมาย' ภายในกลุ่ม

กับดักความคุ้มค่า: เมื่อ ‘ประสิทธิภาพ’ สวนทางกับ ‘ความหมาย’




“LLMs aggressively compress, achieving optimal information-theoretic compression at the cost of semantic richness.”

หลักฐานเชิงประจักษ์: กราฟแสดงความแตกต่างระหว่าง Human vs AI



เส้นประแสดงระดับของมนุษย์ ซึ่งอยู่สูงกว่าเส้นของ AI ทุกโมเดล แสดงให้เห็นว่าโครงสร้างความรู้ของมนุษย์มีความซับซ้อน (Complexity) และความหลากหลาย (Richness) มากกว่าสิ่งที่ AI สร้างขึ้น

“ขนาดไม่ใช่คำตอบ: ชัยชนะของ Encoder Models”




ความเชื่อ: โมเดลยิ่งใหญ่ยิ่งฉลาด (Bigger is Better)

ความจริง: โมเดล **BERT** (340M พารามิเตอร์) เข้าใจโครงสร้างความรู้ได้ดีกว่า **Llama-3** (70B พารามิเตอร์)

การเปรียบเทียบ:

- Encoder (BERT):** มองเห็นทั้งประโยคพร้อมกัน (Bidirectional) -> เข้าใจโครงสร้าง
- Decoder (GPT/Llama):** ทำนายคำถัดไปเรื่อยๆ (Unidirectional) -> เน้นสร้างคำ

‘การเข้าใจ’ และ ‘การพูด’ อาจต้องใช้สมองคนละส่วน



Representation
(การเป็นตัวแทนข้อมูล)
Encoder Strength

ต้องการโครงสร้างที่ชัดเจน
และความสัมพันธ์ที่แม่นยำ




Generation
(การสร้างภาษา)
Decoder Strength

ต้องการความลื่นไหลและ
ความน่าจะเป็นของคำถัดไป

สถาปัตยกรรมปัจจุบันที่รวมทุกอย่างไว้ใน Decoder-only
อาจเป็นการเดินผิดทางสำหรับการสร้าง AI ที่ ‘เข้าใจ’ โลกจริงๆ

วิวัฒนาการทางความคิด: จากการจัดจำ สู่การจัดระเบียบ



ระยะที่ 1: ช่วงแรกของกาฝึกฝน โมเดลเรียนรู้การแบ่งหมวดหมู่พื้นฐานอย่างรวดเร็ว


ระยะที่ 2: โมเดลจะเริ่ม 'ย้าย' ความรู้จากเลเยอร์ลึกๆ ขึ้นมาสู่เลเยอร์ชั้นกลาง เพื่อประหยัดพลังงาน

สรุป: โมเดลไม่ได้แค่เรียนรู้ข้อมูลเพิ่ม แต่กำลัง 'จัดบ้านใหม่' ให้มีประสิทธิภาพสูงสุด

บทสรุปความแตกต่าง: มนุษย์ vs ปัญญาประดิษฐ์

หัวข้อเปรียบเทียบ	มนุษย์ (Human Cognition)	LLM (Artificial Intelligence)
เป้าหมายสูงสุด	ความยืดหยุ่น (Adaptive Utility)	ความคุ้มค่าทางสถิติ (Statistical Efficiency)
โครงสร้างความรู้	มีลำดับชั้นและจุดศูนย์กลาง (Prototype)	แบนราบและเน้นขอบเขต (Boundary)
การจัดเก็บข้อมูล	‘สั่นเปลือง’ เพื่อรักษาบริบท	‘บีบอัด’ เพื่อลดความซ้ำซ้อน
จุดแข็ง	บริบทที่ซับซ้อน	การจัดหมวดหมู่ข้อมูลมหาศาล

ปริศนาของความสมบูรณ์แบบ (The Paradox of Optimization)



เราสร้าง AI โดยตั้งเป้าหมายให้ลดความผิดพลาดทางสถิติ (Minimizing Error)
แต่ผลลัพธ์คือโมเดลที่ตัดทอน ‘ความยุ่งเหยิง’ ซึ่งเป็นหัวใจสำคัญของความหมายในภาษามนุษย์ทิ้งไป


“ความสมบูรณ์แบบทางคณิตศาสตร์ ไม่ใช่สิ่งเดียวกับความเข้าใจ”

อนาคตของ AI: ก้าวข้ามการบีบอัด สู่ความเข้าใจที่แท้จริง




ยอมรับความ ‘ไม่มีประสิทธิภาพ’

ออกแบบโมเดลที่อนุญาตให้มีความ
ซ้ำซ้อนของข้อมูลเหมือนสมองมนุษย์



Hybrid Architecture

ผสาน Encoder (ความเข้าใจ) และ
Decoder (การสื่อสาร) เข้าด้วยกัน



Beyond Statistical Optimality

เล็งวัดความฉลาดด้วยค่า Loss เพียง
แต่ต้องวัดโครงสร้างความรู้ภายใน

From Compression to Comprehension